ĐẠI HỌC QUỐC GIA, THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA

XÁC SUẤT VÀ THỐNG KÊ

BÀI TẬP LỚN

Chủ đề 2 : Computer parts

GVHD: TS. Nguyễn Bá Thi
NHÓM : XSTK - A02 - 09

TP Hồ Chí Minh, Tháng 4 Năm 2025

MỨC ĐỘ ĐÓNG GÓP

Lớp học phần: A02 **Nhóm: 09**

STT	Họ và Tên	MSSV	Công việc được phân công	Mức độ đóng góp	Ký tên	Ghi chú
1	Huỳnh Gia Bảo	2410233	Soạn lý thuyết + gõ LaTeX	100%		
2	Lê Hoàng Long	2411915	Kiểm định 1 mẫu, 2 mẫu	100%		
3	Hoàng Minh Hải	2410898	Tiền xử lý + thống kê mô tả	100%		
4	Nguyễn Anh Quân	2412899	Hồi quy tuyến tính	100%		
5	Lê Nguyễn Anh Tuấn	2233222	Anova	100%		
Tổng cả nhóm				100%		

Nhóm trưởng
(Ký và ghi rõ họ, tên)

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

Mục lục

1 Tổng quan dữ liệu **1**
1.1 Mô tả tập tin 1
1.2 Mô tả biến 1

2 Kiến thức nền **3**
2.1 Thống kê mô tả và thống kê suy diễn 3
2.2 Kiểm định giả thuyết thống kê 4
2.3 Phân tích phương sai 8
2.4 Hồi quy tuyến tính 12

3 Tiền xử lý dữ liệu **14**
3.1 Đọc dữ liệu 14
3.2 Chọn lọc dữ liệu 15
3.3 Xử lí định dạng dữ liệu 15
3.4 Xử lý dữ liệu bị khuyết 16

4 Thống kê mô tả **17**
4.1 Các giá trị đặc trưng của mẫu 17
4.2 Biểu đồ - đồ thị 17

5 Thống kê suy diễn **21**
5.1 Bài toán kiểm định một mẫu 21
5.2 Bài toán kiểm định hai mẫu 23
5.3 Phân tích phương sai nhiều nhân tố 25
5.4 Bài toán hồi quy tuyến tính bội 28

6 Thảo luận và mở rộng **32**

7 Nguồn dữ liệu và code **32**

Tài liệu tham khảo **33**

Danh sách hình vẽ

1 Sơ đồ mối quan hệ thống kê mô tả và suy diễn 3
2 Dữ liệu ban đầu 14
3 Các dữ liệu được chọn lọc 15
4 Dữ liệu sau xử lý định dạng 16
5 Bảng tóm tắt dữ liệu bị khuyết 16
6 Sau xử lý dữ liệu khuyết 16
7 Các giá trị đặc trưng của các biến trong mẫu 17
8 Biểu đồ tần suất các loại bộ nhớ 17
9 Biểu đồ phân bố GPU theo nhà sản xuất (a) và phân bố Notebook GPU (b) 18
10 Biểu đồ tần số của Core speed (a) và Max power (b) 18
11 Biểu đồ tần số của Memory Bandwidth (a) và Memory speed (b). . 19
12 Ma trân tương quan giữa các biến số 19
13 Phân bố công suất tối đa GPU theo loại thiết bị (a) và theo loại bộ nhớ (b). 20
14 Biểu đồ tương quan của Memory Bandwidth với Max Power (a) và TMUs (b) trên các dòng GPU Desktop và Laptop 20
15 Biểu đồ Q-Q của biến `Core_speed` thuộc Nvidia 21
16 Kết quả của hàm `shapiro.test()` 21
17 Miền bác bỏ RR 22
18 Giá trị đặc trưng của mẫu và giá trị kiểm định 22
19 Kết luận 22
20 Biểu đồ Q-Q của VRAM thuộc Nvidia (a) và AMD (b) 23
21 Kết quả của hàm `shapiro.test()` đối với VRAM thuộc Nvidia (a) và AMD (b) 23
22 Miền bác bỏ RR 24
23 Giá trị đặc trưng của các mẫu và giá trị kiểm định 24
24 Tần suất của các tổ hợp 25
25 Biểu đồ Interaction Plot (a) và biểu đồ Boxplot theo hãng và loại thiết bị (b) 25
26 Kết quả kiểm định Levene 26
27 Biểu đồ Q-Q (a) và kết quả `shapiro.test()` (b) 26
28 Kết quả Anova hai nhân tố 27
29 Biểu đồ kiểm định Tukey HSD so sánh khác biệt về Max Power theo từng nhân tố và hiệu ứng tương tác. 27
30 Kết quả đánh giá và chọn lọc biến tối ưu cho mô hình dự đoán `Max_Power`. 28

31 Hệ số xác định của các mô hình và kết quả mô hình tốt nhất 28
32 Hệ số của `base_model` 28
33 Kết quả hàm `vif()` của `base_model` 28
34 Kết quả hàm `vif()` của `model_1` 29
35 Kết quả kiểm định của Memory_Bandwidth 29
36 Kết quả ước lượng hệ số hồi quy và kiểm định t cho các biến của (`base_model`) 29
37 Biểu đồ phần dư (a) và biểu đồ Q-Q của phần dư (b) 30
38 Kết quả hàm `shapiro.test()` (a) và hàm `bptest()` (b) 30
39 Kết quả đánh giá tổng thể mô hình `main_model` 31

1 Tổng quan dữ liệu

1.1 Mô tả tập tin

- **Tên tập tin:** `All_GPUs.csv`
- **Nguồn:** https://www.kaggle.com/datasets/iliassekkaf/computerparts/
- **Số lượng quan sát:** có 3406 quan sát, tương ứng với 3406 quan sát trong tệp dữ liệu
- **Số lượng biến:** có 34 biến, tương ứng với 34 cột trong tệp dữ liệu
- **Mô tả chung:** Bộ dữ liệu này chứa thông số kỹ thuật chi tiết về các card đồ họa (GPU) từ nhiều nhà sản xuất khác nhau.

1.2 Mô tả biến

Tên biến	Kiểu biến	Mô tả
Architecture	Phân loại	Kiến trúc GPU dựa trên đồ họa
Best_Resolution	Phân loại	Kích thước màn hình tốt nhất để giảm thiểu độ trễ
Boost_Clock (MHz)	Liên tục	Xung nhịp tối đa
Core_Speed (MHz)	Liên tục	Tốc độ của card đồ họa
DVI_Connection (kết nối)	Liên tục	Số lượng kết nối DVI đang có
Dedicated	Phân loại	Card đồ họa chuyên dụng
Direct_X	Phân loại	Bộ công nghệ chứa các API
DisplayPort_Connection (kết nối)	Liên tục	Số lượng kết nối DisplayPort đang có
HDMI_Connection (kết nối)	Liên tục	Số lượng kết nối HDMI đang có
Integrated	Phân loại	Tích hợp card đồ họa
L2_Cache (KB)	Liên tục	Kích thước bộ nhớ đệm cấp 2
Manufacturer	Phân loại	Nhà phát hành
Max_Power (Watts)	Liên tục	Công suất chạy card đồ họa
Memory (MB)	Liên tục	Dung lượng bộ nhớ
Memory_Bandwidth (GB/sec)	Liên tục	Băng thông
Memory_Bus (Bit)	Liên tục	Độ lớn kênh truyền dữ liệu
Memory_Speed (MHz)	Liên tục	Tốc độ bộ nhớ RAM của card đồ họa
Memory_Type	Phân loại	Loại bộ nhớ
...		

Tên biến	Kiểu biến	Mô tả
Name	Phân loại	Tên của GPU
Notebook_GPU	Phân loại	Dùng cho máy tính xách tay hay máy tính để bàn
Open_GL	Phân loại	Loại OpenGL mà card có thể hỗ trợ
PSU (Watt & Amps)	Liên tục	Công suất cung cấp điện cho PC
Pixel_Rate (GPixel/s)	Liên tục	Số lượng pixel trên giây có thể tạo ra
Power_Connector	Phân loại	Loại đầu nối nguồn
Process (nm)	Liên tục	Khoảng cách giữa các tính năng giống hệt nhau của một ô nhớ
ROPs (toán tử)	Liên tục	Số lượng toán tử Raster
Release_Date	Phân loại	Ngày phát hành
Release_Price ($)	Liên tục	Giá tiền
Resolution_WxH	Phân loại	Độ phân giải tối đa
SLI_Crossfire	Phân loại	Khả năng kết nối nhiều GPU riêng lẻ
Shader	Liên tục	Công nghệ đồ họa Shader Model
TMUs (đơn vị)	Liên tục	Số lượng đơn vị ánh xạ kết cấu
Texture_Rate (GTexel/s)	Liên tục	Số texture pixels trên giây có thể tạo ra
VGA_Connection (kết nối)	Liên tục	Số lượng kết nối VGA đang có

2 Kiến thức nền

2.1 Thống kê mô tả và thống kê suy diễn

Các bước thu thập, sắp xếp, biểu diễn, tổng hợp, phân tích và phiên giải dữ liệu là các nội dung chính của thống kê. Các nội dung trên được chia thành hai thành phần là: **thống kế mô tả** và **thống kê suy diễn**.

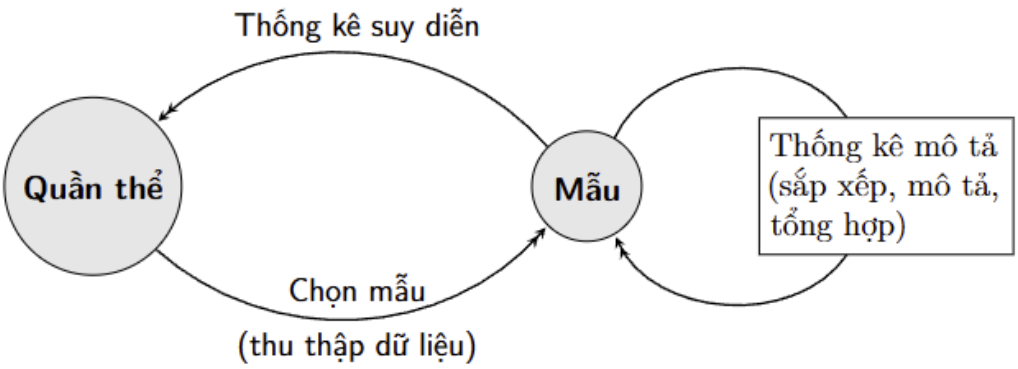

Hình 1: Sơ đồ mối quan hệ thống kê mô tả và suy diễn

2.1.1 Thống kê mô tả

Thống kê mô tả : là quá trình thu thập, sắp xếp, biểu diễn, tổng hợp và xử lý dữ liệu để biến đổi dữ liệu thành thông tin.

- Thu tập dữ liệu: khảo sát, đo đạc, ...
- Biểu diễn dữ liệu: dùng bảng và đồ thị.
- Tổng hợp và xử lý dữ liệu: tính các tham số mẫu như trung bình mẫu, phương sai mẫu, trung vị, ...

2.1.2 Thống kê suy diễn

Thống kê suy diễn : xử lý các thông tin có được từ thống kê mô tả, từ đó đưa ra các cơ sở cho những dự đoán, dự báo và các ước lượng.

- Ước lượng: tham số thống kê (trung bình, tỷ lệ, phương sai, ...).
- Kiểm định giả thuyết: tham số thống kê (trung bình, tỷ lệ, phương sai), quy luật phân phối xác suất (chuẩn, poisson,...), tính độc lập,...

2.2 Kiểm định giả thuyết thống kê

2.2.1 Các khái niệm chung

a) Các giả thuyết thống kê

Định nghĩa 1.1

Một giả thuyết thống kê, hay gọi tắt là giả thuyết, là một phát biểu hay khẳng định về giá trị của một tham số, một vài tham số, hay dạng của phân phối của một quần thể.

- Giả thuyết không (*còn được gọi là giả thuyết* H_0) là một giả thuyết mà ban đầu được giả định là đúng.
- Đối thuyết *(còn được gọi là giả thuyết* H_1) là giả thuyết ngược lại với H_0.

Phương pháp kiểm định thống kê là cách dùng dữ liệu mẫu để kiểm tra xem ta có thể bác bỏ H_0 hay không. Giả thuyết H_0 chỉ bị bác bỏ khi mẫu cho thấy H_0 sai. Hai kết luận có thể có từ một kiểm định thống kê là 'bác bỏ H_0' hay 'không thể bác bỏ H_0'.

Một quy trình kiểm định gồm các bước:

1. Phát biểu giả thuyết H_0 và đối thuyết H_1 của bài toán
2. Tính *giá trị kiểm định thống kê* dựa vào dữ liệu mẫu.
3. Xác đinh miền bác bỏ - tập tất cả các giá trị kiểm định thống kê mà dựa vào đó, ta sẽ bác bỏ được H_0.
4. Đưa ra kết luận. Giả thuyết H_0 bị bác bỏ khi và chỉ khi giá trị kiểm định thống kê thuộc vào miền bác bỏ. Giá trị ngăn cách giữa miền bác bỏ và miền không bác bỏ được gọi là điểm tới hạn.

b) Các loại sai lầm

Định nghĩa 1.2

Có hai loại sai lầm xảy ra khi tiến hành kiểm định thống kê:

- Sai lầm loại I: là sai lầm khi ta bác bỏ H_0 mặc dù H_0 thực sự đúng.
- Sai lầm loại II: là sai lầm khi ta không bác bỏ H_0 mặc dù H_0 thực sự sai.

2.2.2 Kiểm định một mẫu

a) Kiểm định tỉ lệ một mẫu

Nếu ta so sánh tỷ lệ tổng thể p với giá trị cho trước gọi là p_0 thì bài toán này được gọi là kiểm định tỷ lệ một mẫu. Dựa vào mẫu đủ lớn, kiểm định p so với p_0 ở mức ý nghĩa α, với giả định $np_0 \geq 5$, $n(1-p_0) \geq 5$.

Điều kiện: $n \geq 30$	**Tiêu chuẩn kiểm định**	**Miền bác bỏ**
$\begin{cases} H_0 : p = p_0 \\ H_1 : p \neq p_0 \end{cases}$	$z = \dfrac{f - p_0}{\sqrt{\dfrac{p_0(1-p_0)}{n}}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; \infty)$
$\begin{cases} H_0 : p \geq p_0 \\ H_1 : p < p_0 \end{cases}$	$z = \dfrac{f - p_0}{\sqrt{\dfrac{p_0(1-p_0)}{n}}}$	$RR = (-\infty; -z_{\alpha})$
$\begin{cases} H_0 : p \leq p_0 \\ H_1 : p > p_0 \end{cases}$	$z = \dfrac{f - p_0}{\sqrt{\dfrac{p_0(1-p_0)}{n}}}$	$RR = (z_{\alpha}; \infty)$

b) Kiểm định trung bình một mẫu

Cho tổng thể X có kỳ vọng là μ (μ chưa biết). Dùng thống kê từ mẫu, thực hiện kiểm định μ với μ_0 (μ_0 là giá trị cho trước), xét với mức ý nghĩa α.

H_0	H_1	**TCKĐ**	**Miền bác bỏ**
(1) Trường hợp tổng thể có phân phối chuẩn, đã biết σ^2			
$\mu = \mu_0$	$\mu \neq \mu_0$	$z_{qs} = \dfrac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$
	$\mu < \mu_0$		$RR = (-\infty; -z_{\alpha})$
	$\mu > \mu_0$		$RR = (z_{\alpha}; +\infty)$
(2) Trường hợp tổng thể có phân phối chuẩn, chưa biết σ^2			
$\mu = \mu_0$	$\mu \neq \mu_0$	$t_{qs} = \dfrac{\bar{x} - \mu_0}{s/\sqrt{n}}$	$RR = (-\infty; -t_{\alpha/2;n-1}) \cup (t_{\alpha/2;n-1}; +\infty)$
	$\mu < \mu_0$		$RR = (-\infty; -t_{\alpha;n-1})$
	$\mu > \mu_0$		$RR = (t_{\alpha;n-1}; +\infty)$
(3) Trường hợp tổng thể có phân phối tuỳ ý, $n \geq 30$			
$\mu = \mu_0$	$\mu \neq \mu_0$	$z_{qs} = \dfrac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$
	$\mu < \mu_0$		$RR = (-\infty; -z_{\alpha})$
	$\mu > \mu_0$		$RR = (z_{\alpha}; +\infty)$

Lưu ý: Các trường hợp chưa biết σ^2 thì thay bằng phương sai S^2 của mẫu

2.2.3 Kiểm định hai mẫu

a) Kiểm định tỉ lệ hai mẫu

Cho hai tổng thể X và Y, trong đó có tỷ lệ phần tử mang dấu hiệu A nào đó trong hai tổng thể lần lượt là p_1 và p_2 (p chưa biết). Dùng thống kê từ hai mẫu thu được từ hai tổng thể, thực hiện kiểm định để so sánh p_1 và p_2, xét với mức ý nghĩa α.
Giả định:

- Hai mẫu độc lập
- Cỡ mẫu n_1 và n_2 lớn, $n_i f_i \geq 5$ và $n_i(1-f_i) \geq 5 \quad i \in \{1,2\}$

Giả thuyết	Tiêu chuẩn kiểm định	Miền bác bỏ
$\begin{cases} H_0: p_1 = p_2 \\ H_1: p_1 \neq p_2 \end{cases}$	$z_0 = \dfrac{f_1 - f_2}{\sqrt{\dfrac{\bar{f}(1-\bar{f})}{\bar{n}}}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$
$\begin{cases} H_0: p_1 = p_2 \\ H_1: p_1 > p_2 \end{cases}$		$RR = (z_\alpha; +\infty)$
$\begin{cases} H_0: p_1 = p_2 \\ H_1: p_1 < p_2 \end{cases}$		$RR = (-\infty; -z_\alpha)$

Với:

$$\bar{f} = \frac{m_1 + m_2}{n_1 + n_2} \qquad \bar{n} = \frac{n_1 \cdot n_2}{n_1 + n_2}$$

b) Kiểm định trung bình hai mẫu

H_0	H_1	TCKĐ	Miền bác bỏ
(1) Trường hợp đã biết σ_1^2, σ_2^2			
$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$	$z_0 = \dfrac{\bar{x}_1 - \bar{x}_2}{\sqrt{\dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$
	$\mu_1 < \mu_2$		$RR = (-\infty; -z_\alpha)$
	$\mu_1 > \mu_2$		$RR = (z_\alpha; +\infty)$
(2) Trường hợp mẫu lớn $n_1 \geq 30$ và $n_2 \geq 30$			
...			

H_0	H_1	**TCKĐ**	**Miền bác bỏ**
$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$	$z_0 = \dfrac{\bar{x}_1 - \bar{x}_2}{\sqrt{\dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}}}$	$RR = (-\infty; -z_{\alpha/2}) \cup (z_{\alpha/2}; +\infty)$
	$\mu_1 < \mu_2$		$RR = (-\infty; -z_\alpha)$
	$\mu_1 > \mu_2$		$RR = (z_\alpha; +\infty)$
(3) Trường hợp chưa biết σ_1^2, σ_2^2 hoặc $n_1 \leq 30$ và $n_2 \leq 30$			
Trường hợp 3.1: $\sigma_1^2 = \sigma_2^2$			
$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$	$t_0 = \dfrac{\bar{x}_1 - \bar{x}_2}{S_p\sqrt{\dfrac{1}{n_1} + \dfrac{1}{n_2}}}$	$RR = (-\infty; -t_{\alpha/2,df}) \cup (t_{\alpha/2,df}; +\infty)$
	$\mu_1 < \mu_2$		$RR = (-\infty; -t_{\alpha,df})$
	$\mu_1 > \mu_2$		$RR = (t_{\alpha,df}; +\infty)$
Trường hợp 3.2: $\sigma_1^2 \neq \sigma_2^2$			
$\mu_1 = \mu_2$	$\mu_1 \neq \mu_2$	$t_0 = \dfrac{\bar{X}_1 - \bar{X}_2}{\sqrt{\dfrac{S_1^2}{n_1} + \dfrac{S_2^2}{n_2}}}$	$RR = (-\infty; -t_{\alpha/2,df}) \cup (t_{\alpha/2,df}; +\infty)$
	$\mu_1 < \mu_2$		$RR = (-\infty; -t_{\alpha,df})$
	$\mu_1 > \mu_2$		$RR = (t_{\alpha,df}; +\infty)$
(4) Kiểm định trung bình 2 mẫu không độc lập (mẫu phối từng cặp)			
$\mu_D = D_0$	$\mu_D \neq D_0$	$t_0 = \dfrac{\bar{d} - D_0}{s_d/\sqrt{n}}$	$RR = (-\infty; -t_{\alpha/2,n-1}) \cup (t_{\alpha/2,n-1}; +\infty)$
	$\mu_D < D_0$		$RR = (-\infty; -t_{\alpha,n-1})$
	$\mu_D > D_0$		$RR = (t_{\alpha,n-1}; +\infty)$

Trong đó:

- Các trường hợp chưa biết σ^2 thì thay bằng phương sai S^2 của mẫu
- **Trường hợp (3.1)** giả định $\sigma_1^2 = \sigma_2^2$: Ta có bậc tự do $df = n_1 + n_2 - 2$ và phương sai chung $S_p^2 = \dfrac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$
- **Trường hợp (3.2)** giả định $\sigma_1^2 \neq \sigma_2^2$: Bậc tự do df (làm tròn số nguyên theo nguyên tắc quá bán) được tính theo công thức: $df = \dfrac{\left(\dfrac{S_1^2}{n_1} + \dfrac{S_2^2}{n_2}\right)^2}{\dfrac{(S_1^2/n_1)^2}{n_1 - 1} + \dfrac{(S_2^2/n_2)^2}{n_2 - 1}}$

– **Trường hợp (4)** mẫu phối từng cặp: Ta có trung bình mẫu $\bar{d} = \frac{1}{n}\sum_{i=1}^{n} d_i$ (với $d_i = x_i - y_i$) và phương sai mẫu $s_d^2 = \frac{1}{n-1}\sum_{i=1}^{n}(d_i - \bar{d})^2$

2.3 Phân tích phương sai

Phân tích phương sai (Analysis of Variance - ANOVA) là một kỹ thuật thống kê được sử dụng để kiểm định giả thuyết về sự bằng nhau của ba hay nhiều số trung bình tổng thể. Khác với kiểm định t-test chỉ giới hạn ở việc so sánh hai nhóm, ANOVA cho phép đánh giá sự khác biệt giữa nhiều nhóm cùng lúc bằng cách phân tích sự biến thiên của dữ liệu thành các thành phần khác nhau.

2.3.1 ANOVA một nhân tố

a) Mô hình toán học

Mô hình ANOVA một yếu tố (One-way ANOVA) xét tác động của một biến độc lập lên một biến phụ thuộc, được biểu diễn dưới dạng:

$$y_{ij} = \mu + \alpha_i + \epsilon_{ij}$$

Trong đó:

- y_{ij} là giá trị quan sát thứ j trong nhóm thứ i.
- μ là trung bình chung của toàn bộ quần thể.
- α_i là hiệu ứng của nhóm thứ i (thường có ràng buộc $\sum \alpha_i = 0$).
- ϵ_{ij} là sai số ngẫu nhiên, giả sử $\epsilon_{ij} \sim \mathcal{N}(0, \sigma^2)$.

b) Giả thuyết thống kê

Bài toán kiểm định ANOVA xoay quanh cặp giả thuyết cơ bản sau:

- **Giả thuyết không (H_0):** Không có sự khác biệt về trung bình giữa các nhóm. Các mẫu đều được rút ra từ các tổng thể có cùng giá trị trung bình.

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k$$

- **Giả thuyết đối (H_1):** Có ít nhất một cặp nhóm có trung bình khác biệt.

$$H_1 : \exists i \neq j \text{ sao cho } \mu_i \neq \mu_j$$

c) Các giả định của mô hình

Để kết quả của kiểm định ANOVA có ý nghĩa và đáng tin cậy, dữ liệu thu thập cần phải thỏa mãn ba giả định cơ bản:

1. **Tính độc lập:** Các quan sát trong cùng một nhóm và giữa các nhóm phải hoàn toàn độc lập với nhau.
2. **Phân phối chuẩn:** Dữ liệu trong mỗi nhóm phải tuân theo phân phối chuẩn (hoặc xấp xỉ chuẩn nếu cỡ mẫu đủ lớn).
3. **Phương sai đồng nhất:** Các nhóm so sánh phải có phương sai xấp xỉ bằng nhau ($\sigma_1^2 = \sigma_2^2 = \cdots = \sigma_k^2$).

d) Tiêu chuẩn kiểm định

ANOVA tiến hành phân tách tổng độ lệch bình phương của dữ liệu (SST) thành hai thành phần độc lập: độ lệch bình phương giữa các nhóm (SSB) và độ lệch bình phương trong nội bộ nhóm hay sai số (SSW):

$$SST = SSB + SSW$$

Đại lượng thống kê F được tính dựa trên tỷ số giữa phương sai giữa các nhóm (MSB) và phương sai trong nội bộ nhóm (MSW):

$$F = \frac{MSB}{MSW} = \frac{\frac{SSB}{k-1}}{\frac{SSW}{N-k}}$$

Trong đó:

- k là số lượng nhóm.
- N là tổng số lượng các quan sát trên tất cả các nhóm.
- $k-1$ và $N-k$ lần lượt là bậc tự do của tử số và mẫu số.

Nếu giá trị thống kê F tính toán được lớn hơn giá trị F tới hạn tra từ bảng phân phối Fisher ở mức ý nghĩa α (hoặc giá trị $p-\text{value} < \alpha$), ta có đủ cơ sở để bác bỏ giả thuyết H_0, kết luận rằng có sự khác biệt mang ý nghĩa thống kê giữa trung bình của ít nhất hai nhóm.

e) Hệ số xác định (R^2 hoặc η^2):

Để đánh giá mức độ ảnh hưởng của nhân tố lên biến phụ thuộc, ta sử dụng hệ số xác định:

$$R^2 = \frac{SSB}{SST}$$

Hệ số này nhận giá trị trong đoạn $[0, 1]$, cho biết có bao nhiêu phần trăm sự biến thiên của dữ liệu (tổng bình phương SST)

f) Bảng ANOVA

Bảng dưới đây tóm tắt các công thức tính toán để phân rã sự biến thiên. Gọi k là số lượng nhóm, n_i là số quan sát trong nhóm i, và $N = \sum_{i=1}^{k} n_i$ là tổng số quan sát. $\bar{y}_{i.}$ là trung bình của nhóm i, và $\bar{y}_{..}$ là trung bình chung toàn mẫu.

Nguồn biến thiên	**Tổng bình phương**	**Bậc tự do**	**Trung bình bình phương**
Giữa các nhóm	$SSB = \sum_{i=1}^{k} n_i(\bar{y}_{i.} - \bar{y}_{..})^2$	$k - 1$	$MSB = \frac{SSB}{k-1}$
Trong nội bộ nhóm	$SSW = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2$	$N - k$	$MSW = \frac{SSW}{N-k}$
Tổng cộng	$SST = SSB + SSW$	$N - 1$	

2.3.2 ANOVA nhiều nhân tố

ANOVA nhiều nhân tố (Multi-factor ANOVA hay Factorial ANOVA) là phương pháp mở rộng của ANOVA một nhân tố, cho phép đánh giá đồng thời ảnh hưởng của từ hai hay nhiều biến độc lập (nhân tố) lên một biến phụ thuộc, cũng như xem xét sự tương tác giữa các nhân tố này.

a) Mô hình toán học (trường hợp hai nhân tố)

Với hai nhân tố A và B, mô hình ANOVA hai nhân tố có dạng:

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \epsilon_{ijk}$$

Trong đó:

- μ là trung bình chung.
- α_i là hiệu ứng của mức thứ i của nhân tố A.
- β_j là hiệu ứng của mức thứ j của nhân tố B.

- $(\alpha\beta)_{ij}$ là hiệu ứng tương tác giữa hai nhân tố.
- $\epsilon_{ijk} \sim \mathcal{N}(0, \sigma^2)$ là sai số ngẫu nhiên.

b) Ý nghĩa kiểm định

ANOVA nhiều nhân tố cho phép kiểm định đồng thời các giả thuyết:

- Ảnh hưởng riêng lẻ của từng nhân tố:

$$H_0^A : \alpha_1 = \alpha_2 = \cdots = 0, \quad H_0^B : \beta_1 = \beta_2 = \cdots = 0$$

- Ảnh hưởng tương tác giữa các nhân tố:

$$H_0^{AB} : (\alpha\beta)_{ij} = 0 \ \forall i, j$$

c) Phân rã phương sai

Tổng biến thiên của dữ liệu được phân rã thành nhiều thành phần:

$$SST = SSA + SSB + SSAB + SSE$$

Trong đó:

- SSA: biến thiên do nhân tố A.
- SSB: biến thiên do nhân tố B.
- $SSAB$: biến thiên do tương tác giữa A và B.
- SSE: sai số ngẫu nhiên.

e) Giả định

Các giả định của ANOVA nhiều nhân tố tương tự ANOVA một nhân tố:

- Các quan sát độc lập.
- Sai số phân phối chuẩn.
- Phương sai đồng nhất giữa các nhóm.

f) Ý nghĩa

ANOVA một nhân tố giúp đánh giá ảnh hưởng của một yếu tố riêng lẻ lên biến phụ thuộc; trong khi ANOVA nhiều nhân tố cho phép phân tích đồng thời nhiều yếu tố và đặc biệt là sự tương tác giữa chúng, từ đó phản ánh chính xác hơn bản chất của dữ liệu trong các bài toán thực tế.

2.4 Hồi quy tuyến tính

Hồi quy tuyến tính (Linear Regression) là phương pháp thống kê dùng để mô hình hóa mối quan hệ giữa một biến phụ thuộc và một hoặc nhiều biến độc lập thông qua một hàm tuyến tính.

2.4.1 Mô hình toán học

Mô hình hồi quy tuyến tính giả định rằng có mối quan hệ tuyến tính giữa biến phụ thuộc và các biến độc lập. Mục tiêu của hồi quy tuyến tính bội là tìm ra một phương trình tuyến tính tốt nhất để dự đoán giá trị của biến phụ thuộc dựa trên các giá trị của các biến độc lập.

Phương trình hồi quy tuyến tính bội có dạng:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \epsilon_i$$

Trong đó:

- y_i là biến phụ thuộc.
- x_{ij} là biến độc lập thứ j.
- β_0 là hệ số chặn, β_j là hệ số hồi quy.
- $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$ là sai số ngẫu nhiên.

2.4.2 Ước lượng tham số

Các hệ số β thường được ước lượng bằng phương pháp bình phương tối thiểu (Ordinary Least Squares - OLS), bằng cách tối thiểu hóa:

$$\min_{\beta} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

Trong đó:

- y_i là giá trị thực tế của biến phụ thuộc tại mẫu thứ i.
- $\hat{y}_i$ là giá trị dự đoán từ mô hình hồi quy, được tính bởi:

$$\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}$$

Như vậy, phương pháp OLS tìm các hệ số β sao cho tổng bình phương sai số giữa giá trị thực tế và giá trị dự đoán là nhỏ nhất.

2.4.3 Giả định của mô hình

- **Tính tuyến tính:** Quan hệ giữa y và các x là tuyến tính.
- **Độc lập:** Các sai số độc lập nhau.
- Phân phối chuẩn: ϵ_i có phân phối chuẩn.
- **Phương sai không đổi:** $\text{Var}(\epsilon_i) = \sigma^2$.

2.4.4 Hệ số xác định R^2

a) Hệ số xác định (R^2) được biểu diễn bằng công thức:

$$R^2 = \frac{SSR}{SST}$$

Trong đó:

- SSR **(Sum of Squares Regression):** đo lường phần biến thiên của dữ liệu được **giải thích bởi mô hình hồi quy**. Nó thể hiện mức độ mô hình phù hợp với dữ liệu.
- SST **(Sum of Squares Total):** đo lường tổng biến thiên của dữ liệu quan sát so với giá trị trung bình, phản ánh mức độ phân tán ban đầu của dữ liệu.

b) Ý nghĩa của R^2:

- $R^2 = 0$: mô hình không giải thích được sự biến thiên của biến phụ thuộc.
- $R^2 = 1$: mô hình giải thích hoàn toàn sự biến thiên của dữ liệu, dự đoán chính xác (không có sai số).
- $0 < R^2 < 1$: mô hình giải thích được một phần biến thiên của dữ liệu; giá trị càng gần 1 thì mô hình càng phù hợp.

2.4.5 Đánh giá mô hình

- **Hệ số xác định:**
$$R^2 = 1 - \frac{SSE}{SST}$$
cho biết mức độ giải thích của mô hình.
- **Kiểm định ý nghĩa hệ số:** sử dụng kiểm định t cho từng β_j.
- **Kiểm định tổng thể:** sử dụng kiểm định F để đánh giá toàn bộ mô hình.

3 Tiền xử lý dữ liệu

3.1 Đọc dữ liệu

Dữ liệu được đọc từ tệp CSV có tên `All_GPUs.csv` bằng hàm `read.csv`. Sau đó, dùng lệnh `head(gpu_raw)` để hiển thị một số dòng đầu tiên của dữ liệu, mặc định là 6 dòng để xem tổng quát bảng dữ liệu:

```
gpu_raw <- read.csv("All_GPUs.csv") #đọc dữ liệu từ file
head(gpu_raw) #In kết quả 6 dòng đầu tiên
```

```
  Architecture Best_Resolution Boost_Clock Core_Speed DVI_Connection Dedicated Direct_X
1  Tesla G92b                                 738 MHz              2       Yes  DX 10.0
2     R600 XT       1366 x 768                  \n-               2       Yes    DX 10
3    R600 PRO       1366 x 768                  \n-               2       Yes    DX 10
4       RV630       1024 x 768                  \n-               2       Yes    DX 10
5       RV630       1024 x 768                  \n-               2       Yes    DX 10
6       RV630       1024 x 768                  \n-               2       Yes    DX 10
  DisplayPort_Connection HDMI_Connection Integrated L2_Cache Manufacturer Max_Power   Memory
1                     NA               0         No      0KB       Nvidia 141 Watts 1024 MB
2                     NA               0         No      0KB          AMD 215 Watts  512 MB
3                     NA               0         No      0KB          AMD 200 Watts  512 MB
4                     NA               0         No      0KB          AMD            256 MB
5                     NA               0         No      0KB          AMD  45 Watts  256 MB
6                     NA               0         No      0KB          AMD  50 Watts  256 MB
  Memory_Bandwidth Memory_Bus Memory_Speed Memory_Type                            Name
1         64GB/sec   256 Bit      1000 MHz       GDDR3                   GeForce GTS 150
2        106GB/sec   512 Bit       828 MHz       GDDR3            Radeon HD 2900 XT 512MB
3       51.2GB/sec   256 Bit       800 MHz       GDDR3                Radeon HD 2900 Pro
4       36.8GB/sec   128 Bit      1150 MHz       GDDR4 Radeon HD 2600 XT Diamond Edition
5       22.4GB/sec   128 Bit       700 MHz       GDDR3                  Radeon HD 2600 XT
6       35.2GB/sec   128 Bit      1100 MHz       GDDR4     Radeon HD 2600 XT 256MB GDDR4
  Notebook_GPU Open_GL                PSU  Pixel_Rate Power_Connector Process ROPs
1           No     3.3 450 Watt & 38 Amps 12 GPixel/s           None     55nm   16
2           No     3.1 550 Watt & 35 Amps 12 GPixel/s           None     80nm   16
3           No     3.1 550 Watt & 35 Amps 10 GPixel/s           None     80nm   16
4           No     3.3                     3 GPixel/s           None     65nm    4
5           No     3.1 400 Watt & 25 Amps  3 GPixel/s           None     65nm    4
6           No     3.3 400 Watt & 26 Amps  3 GPixel/s           None     65nm    4
    Release_Date Release_Price Resolution_WxH SLI_Crossfire Shader TMUs Texture_Rate
1 \n01-Mar-2009                    2560x1600           Yes      4   64  47 GTexel/s
2 \n14-May-2007                    2560x1600           Yes      4   16  12 GTexel/s
3 \n07-Dec-2007                    2560x1600           Yes      4   16  10 GTexel/s
4 \n01-Jul-2007                    2560x1600           Yes      4    8   7 GTexel/s
5 \n28-Jun-2007                    2560x1600           Yes      4    8   6 GTexel/s
6 \n26-Jun-2007                    2560x1600           Yes      4    8   6 GTexel/s
  VGA_Connection
1              0
2              0
3              0
4              0
5              0
6              0
```

Hình 2: Dữ liệu ban đầu

3.2 Chọn lọc dữ liệu

Từ 34 tiêu chí có trong bảng ta chọn ra 11 tiêu chí quan trọng của GPU để xử lí: `Core_Speed`, `Manufacturer`, `Max_Power`, `Memory_Type`, `Memory`, `Memory_Bandwidth`, `Memory_Speed`, `Memory_Bus`, `Process`, `ROPs`, `TMUs`

```
gpu <- gpu_raw[, c("Manufacturer", "Core_Speed", "Max_Power", "Memory_Type",
                   "Memory", "Memory_Bandwidth", "Memory_Speed", "Memory_Bus",
                   "Process", "ROPs", "TMUs", "Notebook_GPU") ]
head(gpu)
```

Ở đây, chỉ các cột cần thiết cho phân tích được giữ lại trong một tập dữ liệu mới gpu để tối ưu hóa quá trình xử lý và phân tích.

	Manufacturer	Core_Speed	Max_Power	Memory_Type	Memory	Memory_Bandwidth	Memory_Speed	Memory_Bus	Process	ROPs	TMUs	Notebook_GPU
1	Nvidia	738 MHz	141 Watts	GDDR3	1024 MB	64GB/sec	1000 MHz	256 Bit	55nm	16	64	No
2	AMD	\n-	215 Watts	GDDR3	512 MB	106GB/sec	828 MHz	512 Bit	80nm	16	16	No
3	AMD	\n-	200 Watts	GDDR3	512 MB	51.2GB/sec	800 MHz	256 Bit	80nm	16	16	No
4	AMD	\n-		GDDR4	256 MB	36.8GB/sec	1150 MHz	128 Bit	65nm	4	8	No
5	AMD	\n-	45 Watts	GDDR3	256 MB	22.4GB/sec	700 MHz	128 Bit	65nm	4	8	No
6	AMD	\n-	50 Watts	GDDR4	256 MB	35.2GB/sec	1100 MHz	128 Bit	65nm	4	8	No

Hình 3: Các dữ liệu được chọn lọc

3.3 Xử lí định dạng dữ liệu

Giai đoạn xử lý dữ liệu của các biến bao gồm việc loại bỏ các đơn vị như `MHz`, `Watts`, ... và xử lý phù hợp với từng biến sau đó chuyển đổi các giá trị còn lại về kiểu số thực hoặc Boolean.

```
#Hàm xử lý ROPs
process_multiplier <- function(column) {
  column <- as.character(column)
  base_val <- as.numeric(str_extract(column, "\\d+"))
  mult_raw <- str_extract(column, "(?i)x[^0-9]*\\d+")
  mult <- as.numeric(str_extract(mult_raw, "\\d+"))
  mult[is.na(mult)] <- 1
  return(base_val * mult)
}
gpu_data[] <- lapply(gpu_data, function(x) gsub("^\\n- $", NA, x))
gpu_clean <- gpu_data %>%
  mutate(
    # Xóa đơn vị và chuyển thành numeric
    Core_Speed = as.numeric(str_remove(Core_Speed, " MHz")),
    Max_Power = as.numeric(str_remove(Max_Power, " Watts")),
    Memory = as.numeric(str_remove(Memory, " MB")),
    Memory_Speed = as.numeric(str_remove(Memory_Speed, " MHz")),
    Memory_Bus = as.numeric(str_remove(Memory_Bus, " Bit")),
    Process = as.numeric(str_remove(Process, "nm")),
    TMUs = as.numeric(str_extract(as.character(TMUs), "[\\d\\.]+")),
    # Xử lý Bandwidth
    Memory_Bandwidth = ifelse(str_detect(Memory_Bandwidth, "MB/sec"),
                              as.numeric(str_extract(Memory_Bandwidth, "[\\d\\.]+")) / 1000,
                              as.numeric(str_extract(Memory_Bandwidth, "[\\d\\.]+"))),
    # Xử lý ROPs
    ROPs = process_multiplier(ROPs),
    # Chuẩn hóa các chuỗi rỗng hoặc "\n-" thành NA
    Manufacturer = ifelse(Manufacturer %in% c("", "\n-", " "), NA, trimws(Manufacturer)),
    Memory_Type = ifelse(Memory_Type %in% c("", "\n-", " "), NA, trimws(Memory_Type)),
    # Chuyển Notebook_GPU thành Boolean (TRUE/FALSE)
    Notebook_GPU = ifelse(Notebook_GPU == "Yes", TRUE, FALSE)
 ) %>%
filter(Manufacturer %in% c("Nvidia", "AMD", "Intel", "ATI"))
head(gpu_clean)
```

```
  Manufacturer Core_Speed Max_Power Memory_Type Memory Memory_Bandwidth Memory_Speed Memory_Bus Process ROPs TMUs Notebook_GPU
1       Nvidia        738       141       GDDR3   1024            64.0         1000        256      55   16   64         FALSE
2          AMD         NA       215       GDDR3    512           106.0          828        512      80   16   16         FALSE
3          AMD         NA       200       GDDR3    512            51.2          800        256      80   16   16         FALSE
4          AMD         NA        NA       GDDR4    256            36.8         1150        128      65    4    8         FALSE
5          AMD         NA        45       GDDR3    256            22.4          700        128      65    4    8         FALSE
6          AMD         NA        50       GDDR4    256            35.2         1100        128      65    4    8         FALSE
```

Hình 4: Dữ liệu sau xử lý định dạng

3.4 Xử lý dữ liệu bị khuyết

Để kiểm tra các dữ liệu bị khuyết trong tập dữ liệu, nhóm sử dụng lệnh: `is.na()` để xác định các giá trị thiếu trong mỗi cột, kết hợp với `colSums()` để tính tổng số lượng NA trong mỗi cột.

```r
na_summary <- data.frame(
  Variable = names(gpu_clean),
  Missing_Count = colSums(is.na(gpu_clean)),
  Missing_Percentage = round(colMeans(is.na(gpu_clean)) * 100, 2)
)
print(na_summary)
```

```
                          Variable Missing_Count Missing_Percentage
Manufacturer         Manufacturer             0                0.00
Core_Speed             Core_Speed           936               27.48
Max_Power               Max_Power           625               18.35
Memory_Type           Memory_Type            56                1.64
Memory                     Memory           420               12.33
Memory_Bandwidth Memory_Bandwidth           121                3.55
Memory_Speed         Memory_Speed           105                3.08
Memory_Bus             Memory_Bus            62                1.82
Process                    Process           463               13.59
ROPs                          ROPs           538               15.80
TMUs                          TMUs           538               15.80
Notebook_GPU         Notebook_GPU             0                0.00
```

Hình 5: Bảng tóm tắt dữ liệu bị khuyết

Dựa bảng tóm tắt dữ liệu bị khuyết, các biến có tỉ lệ bị khuyết thấp sẽ bị xóa các dòng bị khuyết trong `gpu_clean` và các biến có tỷ lệ khuyết cao sẽ được điền vào giá trị `median` ứng với biến đó.

```r
gpu_clean <- gpu_clean %>%
  mutate(
    Core_Speed = ifelse(is.na(Core_Speed), median(Core_Speed, na.rm = TRUE), Core_Speed),
    Memory = ifelse(is.na(Memory), median(Memory, na.rm = TRUE), Memory),
    Process = ifelse(is.na(Process), median(Process, na.rm = TRUE), Process),
    ROPs = ifelse(is.na(ROPs), median(ROPs, na.rm = TRUE), ROPs),
    TMUs = ifelse(is.na(TMUs), median(TMUs, na.rm = TRUE), TMUs),
    Max_Power = ifelse(is.na(Max_Power), median(Max_Power, na.rm = TRUE), Max_Power)
  )
print(colSums(is.na(gpu_clean)))
```

```
Manufacturer       Core_Speed        Max_Power      Memory_Type           Memory Memory_Bandwidth
           0                0                0                0                0                0
Memory_Speed       Memory_Bus          Process             ROPs             TMUs     Notebook_GPU
           0                0                0                0                0                0
```

Hình 6: Sau xử lý dữ liệu khuyết

4 Thống kê mô tả

4.1 Các giá trị đặc trưng của mẫu

Đối với các biến định lượng (liên tục và rời rạc), ta thực hiện tính thống kê mô tả bao gồm trung bình, độ lệch chuẩn mẫu, các phân vị, trung vị, giá trị lớn nhất và giá trị nhỏ nhất. Đối với các biến phân loại, ta lập bảng thống kê số lượng cho các phân loại.

```
gpu_clean $ Manufacturer<-as.factor(gpu_clean$Manufacturer)
gpu_clean $ Memory_Type<-as.factor(gpu_clean$Memory_Type)
summary(gpu_clean)
```

```
 Manufacturer    Core_Speed       Max_Power       Memory_Type        Memory       Memory_Bandwidth
 AMD   :1267   Min.   : 100.0   Min.   :  1.0   GDDR5  :2020   Min.   :   16   Min.   :   1.0
 ATI   :  85   1st Qu.: 850.0   1st Qu.: 60.0   DDR3   : 624   1st Qu.: 1024   1st Qu.:  28.8
 Intel : 223   Median : 980.0   Median :106.0   GDDR3  : 297   Median : 2048   Median : 105.8
 Nvidia:1710   Mean   : 954.8   Mean   :123.5   DDR    : 106   Mean   : 2804   Mean   : 138.2
               3rd Qu.:1050.0   3rd Qu.:150.0   DDR2   :  80   3rd Qu.: 4096   3rd Qu.: 194.6
               Max.   :1784.0   Max.   :780.0   GDDR5X :  79   Max.   :32000   Max.   :1280.0
                                                (Other):  79
  Memory_Speed     Memory_Bus        Process           ROPs              TMUs         Notebook_GPU
 Min.   : 100   Min.   :  32.0   Min.   : 14.0   Min.   :  1.00   Min.   :  1.00   Mode :logical
 1st Qu.: 800   1st Qu.: 128.0   1st Qu.: 28.0   1st Qu.: 16.00   1st Qu.: 32.00   FALSE:2628
 Median :1150   Median : 128.0   Median : 28.0   Median : 32.00   Median : 56.00   TRUE :657
 Mean   :1176   Mean   : 207.2   Mean   : 31.3   Mean   : 31.33   Mean   : 67.87
 3rd Qu.:1502   3rd Qu.: 256.0   3rd Qu.: 40.0   3rd Qu.: 32.00   3rd Qu.: 96.00
 Max.   :2127   Max.   :8192.0   Max.   :150.0   Max.   :192.00   Max.   :384.00
```

Hình 7: Các giá trị đặc trưng của các biến trong mẫu

4.2 Biểu đồ - đồ thị

4.2.1 Phương pháp biểu đồ Bar plot

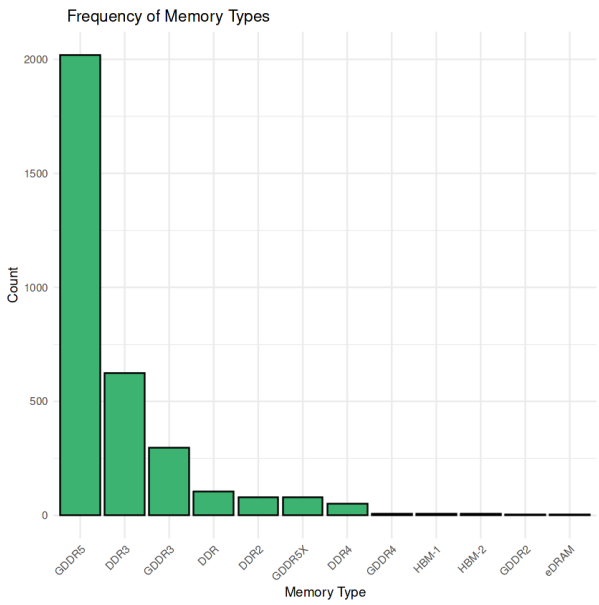

Hình 8: Biểu đồ tần suất các loại bộ nhớ

Nhận xét: "GDDR5", "GDDR3", "DDR3" là các loại phổ biến nhất

4.2.2 Phương pháp biểu đồ Pie chart

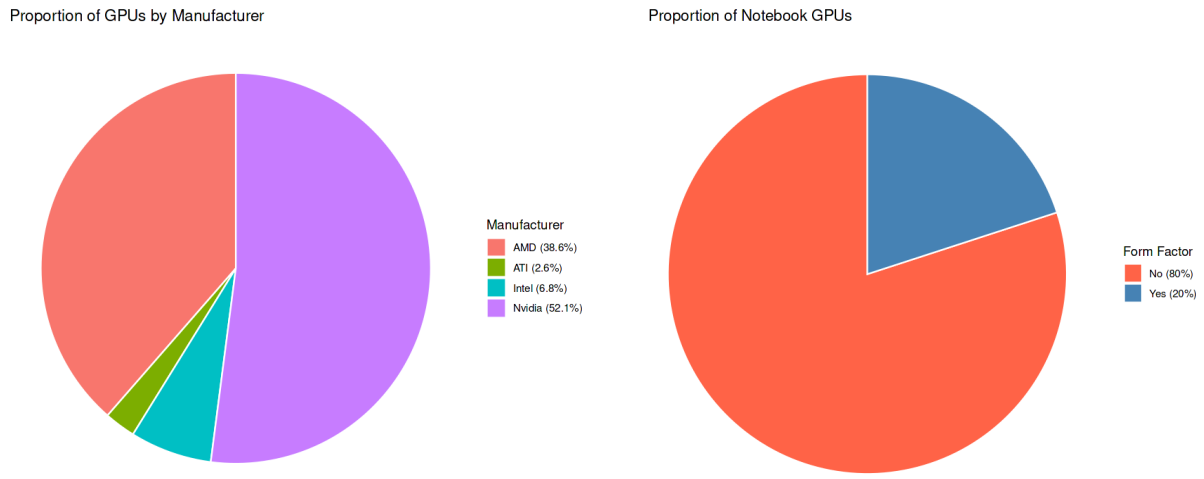

(a) (b)

Hình 9: Biểu đồ phân bố GPU theo nhà sản xuất (a) và phân bố Notebook GPU (b)

Nhận xét: Kết quả cho thấy GPU của hai nhà sản xuất AMD và NVIDIA chiếm tỷ trọng chủ yếu trong tập dữ liệu. Bên cạnh đó, biến phân loại về GPU trên máy tính xách tay có sự mất cân bằng, với tỷ lệ giữa hai nhóm "No" và "Yes" là 80/20.

4.2.3 Phương pháp biểu đồ Histogram

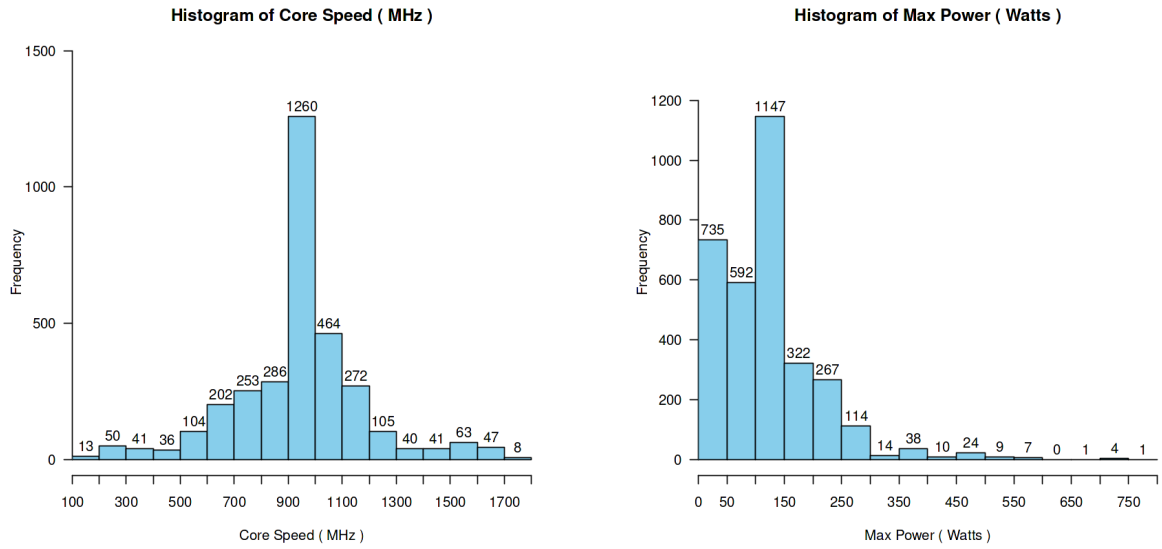

(a) (b)

Hình 10: Biểu đồ tần số của Core speed (a) và Max power (b)

Nhận xét: Ở biểu đồ tần suất của Core Speed ta thấy có hình dạng gần với phân phối chuẩn. Trái lại, biểu đồ tần số của Max Power lệch trái và giảm dần theo hướng với phía phải.

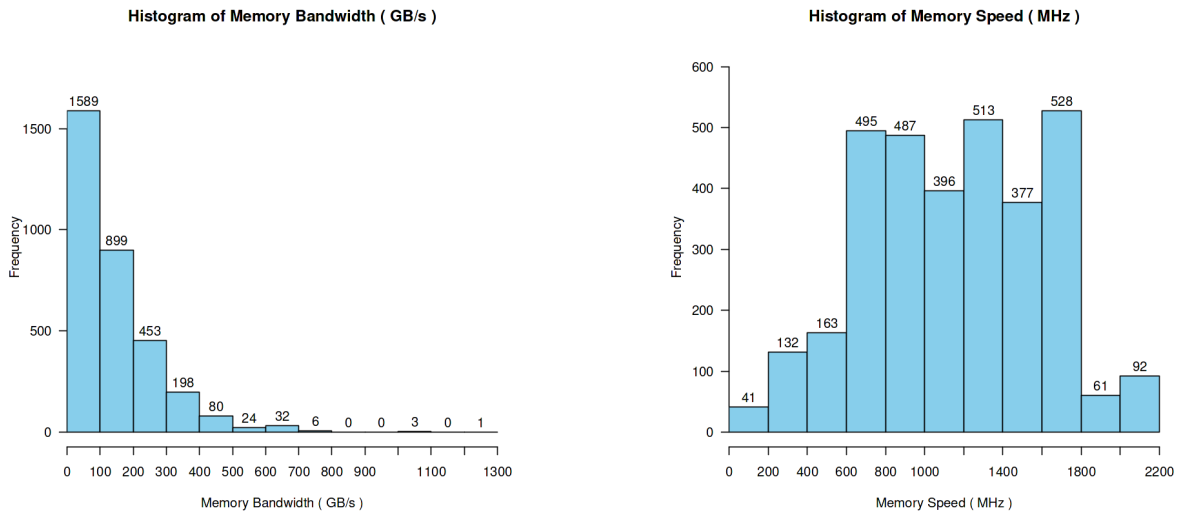

(a) (b)

Hình 11: Biểu đồ tần số của Memory Bandwidth (a) và Memory speed (b).

Nhận xét: Biểu đồ (a) có phân phối lệch phải, phần lớn giá trị dưới 300 GB/s. Biểu đồ (b) có phân phối đa đỉnh, phản ánh dữ liệu gồm nhiều nhóm GPU với các mức hiệu năng khác nhau.

4.2.4 Phương pháp biểu đồ Pair plot

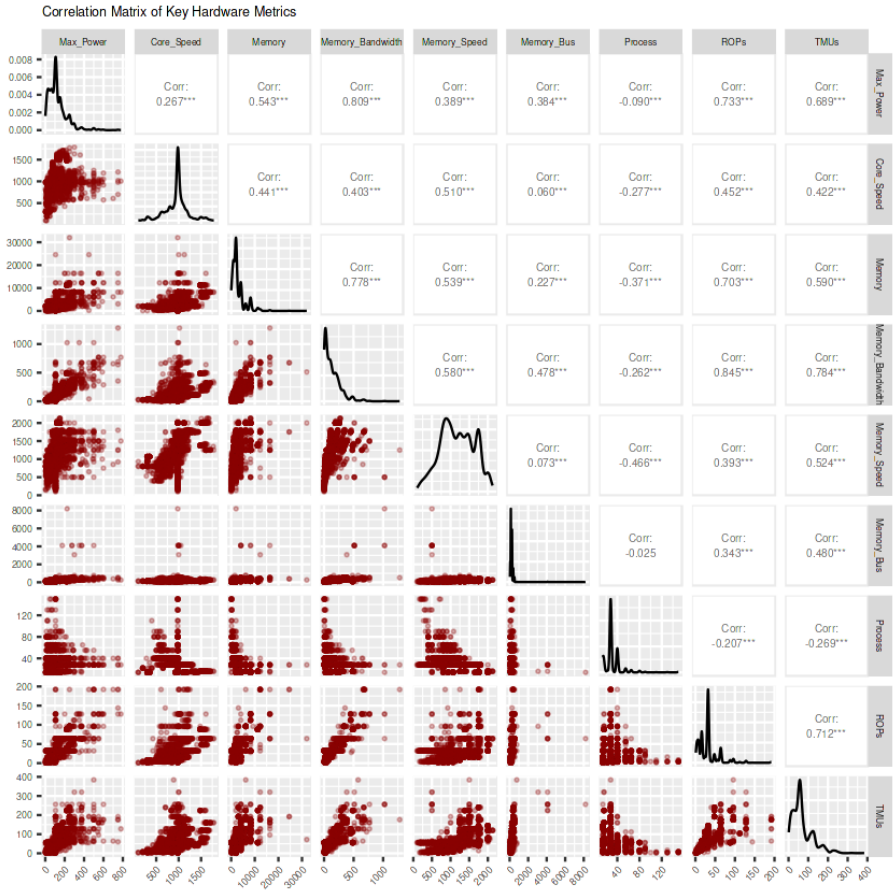

Hình 12: Ma trận tương quan giữa các biến số

Nhận xét: Biểu đồ cho thấy nhiều biến đầu vào có tương quan mạnh. Cần kiểm tra lại nếu dùng cho bài toán hồi quy tuyến tính.

4.2.5 Phương pháp biểu đồ Boxplot

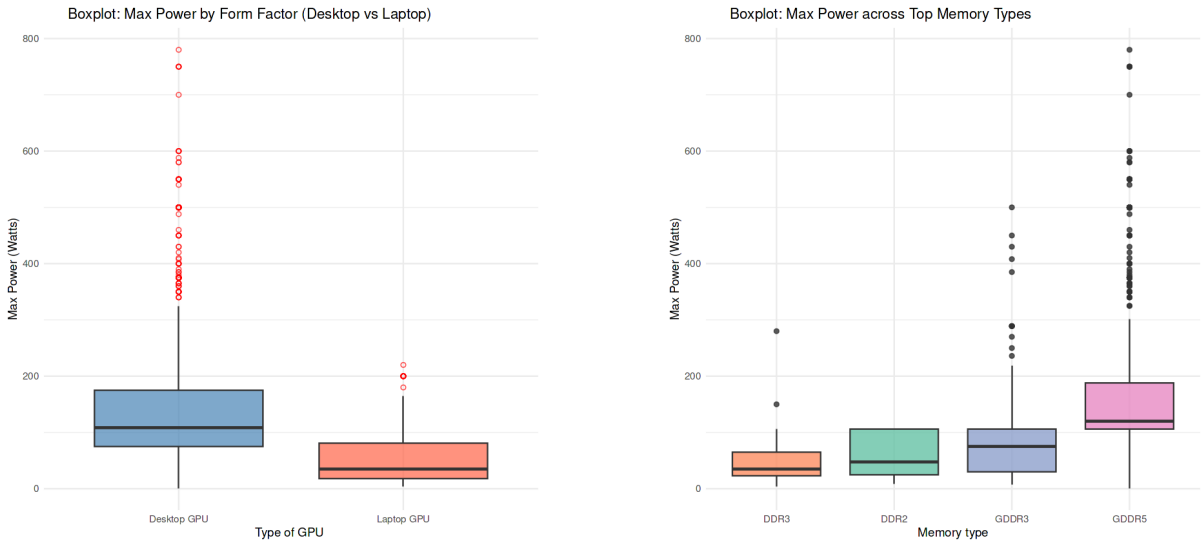

(a) (b)

Hình 13: Phân bố công suất tối đa GPU theo loại thiết bị (a) và theo loại bộ nhớ (b).

Nhận xét: Hộp của Desktop GPU dài hơn, cho thấy sự phân tán dữ liệu rất lớn. Sự khác biệt về trung vị và không chồng lấp giữa các "hộp" là dấu hiệu cho thấy kết quả kiểm định sẽ có ý nghĩa thống kê.

4.2.6 Phương pháp biểu đồ Pair plot

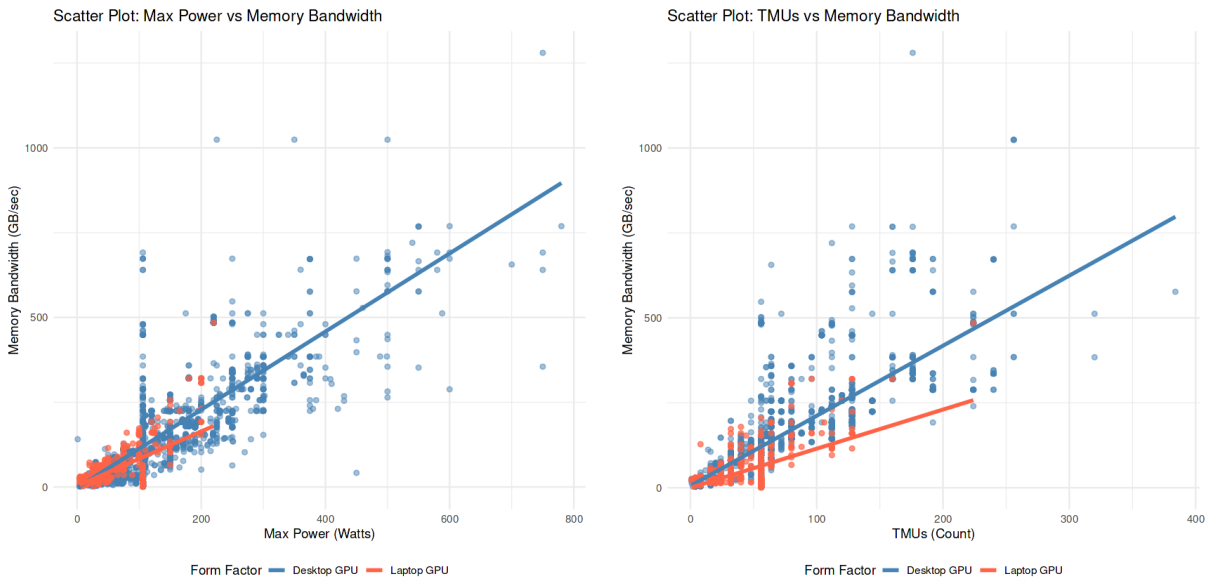

(a) (b)

Hình 14: Biểu đồ tương quan của Memory Bandwidth với Max Power (a) và TMUs (b) trên các dòng GPU Desktop và Laptop

Nhận xét: Nhìn chung, cả hai biểu đồ đều cho thấy Memory Bandwidth có quan hệ tuyến tính dương với Max Power và TMUs ở cả GPU Destop và Laptop.

5 Thống kê suy diễn

5.1 Bài toán kiểm định một mẫu

Bài toán: *Nhiều nguồn tin cho rằng tốc độ lõi (`Core_Speed`) trung bình của GPU hãng NVIDIA lớn hơn mức tiêu chuẩn 950 MHz, hãy tiến hành kiểm định giả thuyết này có đúng hay không với mức ý nghĩa là 5%.*

Giả thiết kiểm định:

$$\begin{cases} H_0 : \mu \leq 950 & (\texttt{Core_Speed} \text{ trung bình của các GPU do Nvidia sản xuất không lớn hơn 950MHz}) \\ H_1 : \mu > 950 & (\texttt{Core_Speed} \text{ trung bình của các GPU do Nvidia sản xuất lớn hơn 950MHz}) \end{cases}$$

Kiểm tra phân phối chuẩn: Quan sát biểu đồ Q-Q để đánh giá `Core_speed` của Nvidia có tuân theo phân phối chuẩn không:

```r
qqnorm(nvidia_coreSpeed) #biến nvidia_coreSpeed được trích từ gpu_clean
qqline(nvidia_coreSpeed)
```

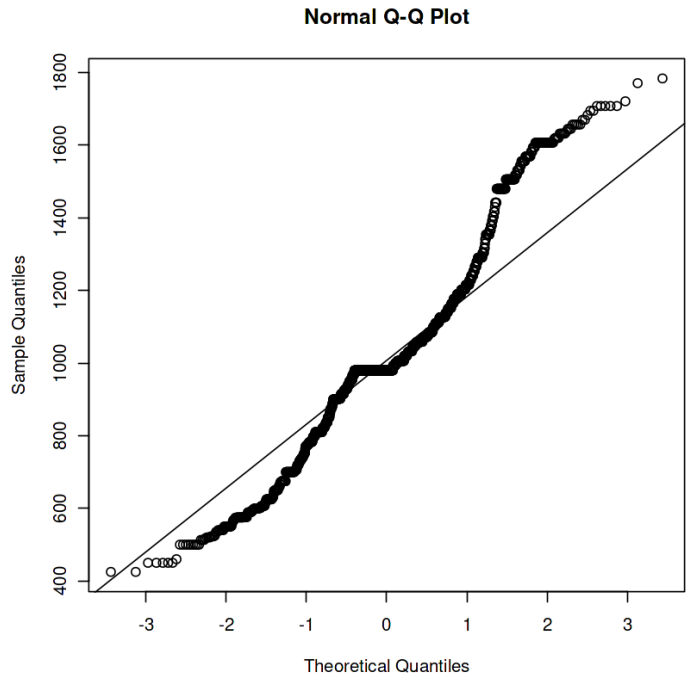

Hình 15: Biểu đồ Q-Q của biến `Core_speed` thuộc Nvidia

Nhận xét: Quan sát biểu đồ Q-Q plot, ta thấy phần lớn các điểm phân vị của dữ liệu thực tế bị lệch khỏi đường thẳng chuẩn. Điều này cho thấy dữ liệu không có dạng phân phối chuẩn.

Kiểm tra lại nhận định bằng hàm `shapiro.test()` trong R:

```
        Shapiro-Wilk normality test

data:  nvidia_coreSpeed
W = 0.95833, p-value < 2.2e-16
```

Hình 16: Kết quả của hàm `shapiro.test()`

Vì `p-value` rất nhỏ (nhỏ hơn mức ý nghĩa $\alpha = 0.05$), vậy nên biến `Core_speed` của GPU Nvidia không tuân theo phân phối chuẩn.

Xác định dạng bài toán:

- X có phân phối tùy ý
- Mẫu lớn: $n \geq 30$ (Nvidia có số lượng mẫu $1710 \geq 30$ ở Hình 7)
- Trường hợp chưa biết σ^2
- Mức ý nghĩa $\alpha = 0.05$

Vậy miền bác bỏ của bài toán trên sẽ có dạng là $RR = (z_\alpha, +\infty)$

Để bác bỏ hoặc chấp nhận H_0 ta lần lượt tìm miền bác bỏ và giá trị kiểm định của bài toán:

Miền bác bỏ RR (với mức ý nghĩa $\alpha = 0.05$):

```r
z_alpha <- qnorm(1 - 0.05)
cat("Xác định miền bác bỏ W: \n")
cat("Giá trị tới hạn z_alpha:", z_alpha, "\n")
cat("Miền bác bỏ: W = (", z_alpha, "; + )\n", sep="")
```

```
Xác định miền bác bỏ W:
Giá trị tới hạn z_alpha: 1.644854
Miền bác bỏ: W = (1.644854; +∞ )
```

Hình 17: Miền bác bỏ RR

Tính toán giá trị kiểm định z_{qs}:

```r
x_bar <- mean(nvidia_coreSpeed)
s <- sd(nvidia_coreSpeed)
n <- length(nvidia_coreSpeed)
z_qs <- (x_bar - 950) / (sd / sqrt(n))
cat("Trung bình mẫu (x_bar):", x_bar, "\n")
cat("Độ lệch chuẩn (sd):", sd, "\n")
cat("Kích thước mẫu (n):", n, "\n")
cat("Giá trị kiểm định z_qs:", z_qs, "\n")
```

```
Trung bình mẫu (x_bar): 1011.34
Độ lệch chuẩn (sd): 252.6002
Kích thước mẫu (n): 1710
Giá trị kiểm định z_qs: 10.04178
```

Hình 18: Giá trị đặc trưng của mẫu và giá trị kiểm định

Kết luận:

```r
if(z_qs > z_alpha){
    cat (" Bác bỏ H0\n")
} else{
    cat (" Không bác bỏ H0: Không có đủ bằng chứng thống kế\n")
}
```

```
Bác bỏ H0
```

Hình 19: Kết luận

Vì $z_{qs} \in RR = (z_\alpha, +\infty)$. Ở mức ý nghĩa 5%, chúng ta có đầy đủ bằng chứng thống kê để bác bỏ giả thiết H_0, thừa nhận giả thiết H_1. Điều này khẳng định rằng `Core_speed` trung bình của các GPU do hãng Nvidia sản xuất lớn hơn 950 MHz.

5.2 Bài toán kiểm định hai mẫu

Bài toán: *Trong việc huấn luyện các mô hình trí tuệ nhân tạo, dung lượng bộ nhớ đồ họa (VRAM) là một yếu tố then chốt. Có quan điểm cho rằng các dòng GPU của hãng NVIDIA có dung lượng VRAM (`Memory`) trung bình lớn hơn so với các dòng GPU của hãng AMD. Hãy kiểm định xem liệu quan điểm này có cơ sở thống kê hay không với mức ý nghĩa 5%.*

Giả thiết kiểm định:

$$\begin{cases} H_0 : \mu_1 \leq \mu_2 & \text{(Dung lượng VRAM trung bình của NVIDIA không lớn hơn AMD)} \\ H_1 : \mu_1 > \mu_2 & \text{(Dung lượng VRAM trung bình của NVIDIA thực sự lớn hơn AMD)} \end{cases}$$

Trong đó:

- μ_1 là dung lượng VRAM (Memory) trung bình của các dòng GPU hãng NVIDIA.
- μ_2 là dung lượng VRAM (Memory) trung bình của các dòng GPU hãng AMD.

Kiểm tra phân phối chuẩn: ta sẽ xét tương tự như trong bài toán một mẫu

```r
qqnorm(nvidia_vram, main = "Q-Q Plot cho VRAM NVIDIA")
qqline(nvidia_vram, col = "red")
qqnorm(amd_vram, main = "Q-Q Plot cho VRAM AMD")
qqline(amd_vram, col = "blue")
```

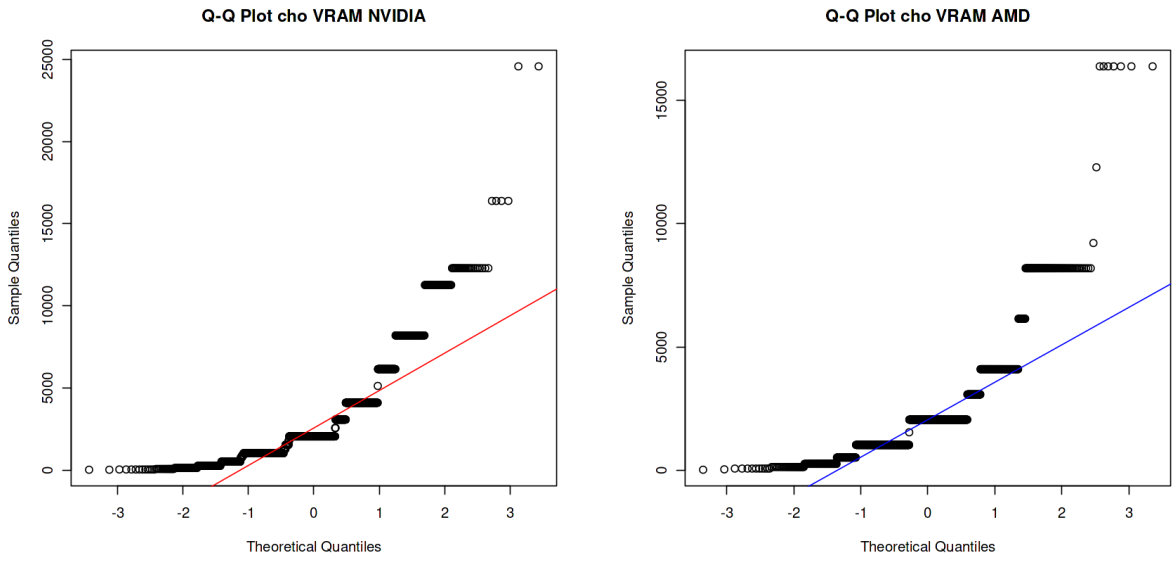

(a) (b)

Hình 20: Biểu đồ Q-Q của VRAM thuộc Nvidia (a) và AMD (b)

Tiếp tục kiểm định bằng hàm `shapiro.test()` trong R:

```
        Shapiro-Wilk normality test

data:  nvidia_vram
W = 0.78521, p-value < 2.2e-16
```

(a)

```
        Shapiro-Wilk normality test

data:  amd_vram
W = 0.74322, p-value < 2.2e-16
```

(b)

Hình 21: Kết quả của hàm `shapiro.test()` đối với VRAM thuộc Nvidia (a) và AMD (b)

Nhận xét: Cả phương pháp đồ thị (Q-Q Plot) và phương pháp kiểm định giả thuyết (Shapiro-Wilk) đều cho thấy dữ liệu VRAM của Nvidia và AMD không có phân phối chuẩn.

Xác định dạng bài toán:

- X_1 và X_2 độc lập với nhau và có phân phối tùy ý
- Mẫu lớn: $n \geq 30$ (Dữ liệu của 2 mẫu Nvidia và AMD đều lớn hơn 30 (Hình 7))
- Trường hợp chưa biết phương sai tổng thể σ_1^2, σ_2^2

Vậy miền bác bỏ của bài toán trên sẽ có dạng là $RR = (z_\alpha, +\infty)$.

Ta sẽ tiếp tục tìm miền bác bỏ và giá trị kiểm định của bài toán để bác bỏ hoặc chấp nhận H_0.

Miền bác bỏ RR (với mức ý nghĩa $\alpha = 0.05$):

```r
z_alpha <- qnorm(1 - 0.05)
cat("Xác định miền bác bỏ W: \n")
cat("Giá trị tới hạn z_alpha:", z_alpha, "\n")
cat("Miền bác bỏ: W = (", z_alpha, "; + )\n", sep="")
```

```
Xác định miền bác bỏ W:
Giá trị tới hạn z_alpha: 1.644854
Miền bác bỏ: W = (1.644854; +∞ )
```

Hình 22: Miền bác bỏ RR

Tính toán giá trị kiểm định z_{qs}:

```r
# Tính toán các đặc trưng mẫu cho NVIDIA
n1 <- length(nvidia_vram)
x1_bar <- mean(nvidia_vram)
s1 <- sd(nvidia_vram)
# Tính toán các đặc trưng mẫu cho AMD
n2 <- length(amd_vram)
x2_bar <- mean(amd_vram)
s2 <- sd(amd_vram)
# Tính toán giá trị kiểm định z_{qs}
z_qs <- (x1_bar - x2_bar) / sqrt((s1^2 / n1) + (s2^2 / n2))
# Hiển thị bảng thông số tóm tắt
cat("--- THÔNG SỐ MẪU NVIDIA ---\n")
cat("Kích thước mẫu (n1): ", n1, "\n")
cat("Trung bình (x1_bar):  ", x1_bar, " MB\n")
cat("Độ lệch chuẩn (s1):   ", s1, "\n\n")
cat("--- THÔNG SỐ MẪU AMD ---\n")
cat("Kích thước mẫu (n2): ", n2, "\n")
cat("Trung bình (x2_bar):  ", x2_bar, " MB\n")
cat("Độ lệch chuẩn (s2):   ", s2, "\n\n")
cat("--- KẾT QUẢ TÍNH TOÁN ---\n")
cat("Giá trị kiểm định z_qs: ", z_qs, "\n")
```

```
--- THÔNG SỐ MẪU NVIDIA ---
Kích thước mẫu (n1):  1710
Trung bình (x1_bar):   3039.289  MB
Độ lệch chuẩn (s1):    2910.77

--- THÔNG SỐ MẪU AMD ---
Kích thước mẫu (n2):  1267
Trung bình (x2_bar):   2433.957  MB
Độ lệch chuẩn (s2):    2266.853

--- KẾT QUẢ TÍNH TOÁN ---
Giá trị kiểm định z_qs:  6.377048
```

Hình 23: Giá trị đặc trưng của các mẫu và giá trị kiểm định

Kết luận:

Vì $z_{qs} \in RR = (z_\alpha, +\infty)$. Ở mức ý nghĩa 5%, chúng ta có đầy đủ bằng chứng thống kê để bác bỏ giả thiết H_0, thừa nhận giả thiết H_1.

5.3 Phân tích phương sai nhiều nhân tố

Mục tiêu của phần này là xem xét sự tác động đồng thời của nhà sản suất (`Manufacture`) và loại thiết bị (`Notebook_GPU`) lên mức tiêu thụ điện năng tối đa của GPU (`Max_Power`)

a) Mục tiêu và giả thiết: mục tiêu là xác định xem liệu sự khác biệt về điện năng (`Max_Power`) có phụ thuộc vào việc GPU đó thuộc hãng nào, là dòng cho Laptop hay Desktop, và quan trọng nhất là liệu có sự tương tác giữa hai yếu tố này hay không. Các cặp giả thuyết (H_0):

1. **Hãng sản xuất:** Không có sự khác biệt về điện năng trung bình giữa các hãng.
2. **Loại thiết bị:** Không có sự khác biệt về điện năng trung bình giữa dòng Laptop và Desktop.
3. **Sự tương tác:** Hiệu ứng của loại thiết bị lên điện năng tối đa không phụ thuộc vào hãng sản xuất.

b) Tiền xử lý dữ liệu cho ANOVA 2 nhân tố:

```r
# Lọc dữ liệu cho mô hình 2 nhân tố
df_2way <- gpu_clean %>%
  filter(Manufacturer != "ATI") %>%
  group_by(Manufacturer, Notebook_GPU) %>%
  filter(n() > 20) %>%
  ungroup() %>%
  mutate(
    Manufacturer = as.factor(Manufacturer),
    Notebook_GPU = as.factor(ifelse(as.logical(Notebook_GPU), "Laptop", "Desktop"))
  )
df_2way <- df_2way %>%
  droplevels()
cat("--- BẢNG TẦN SUẤT CÁC NHÓM TỔ HỢP ---\n")
table(df_2way$Manufacturer, df_2way$Notebook_GPU)
```

```
--- BẢNG TẦN SUẤT CÁC NHÓM TỔ HỢP ---

        Desktop Laptop
  AMD      1022    245
  Intel      89    134
  Nvidia   1432    278
```

Hình 24: Tần suất của các tổ hợp

c) Trực quan hóa dữ: Sử dụng Interaction Plot để quan sát sự biến thiên của biến phụ thuộc.

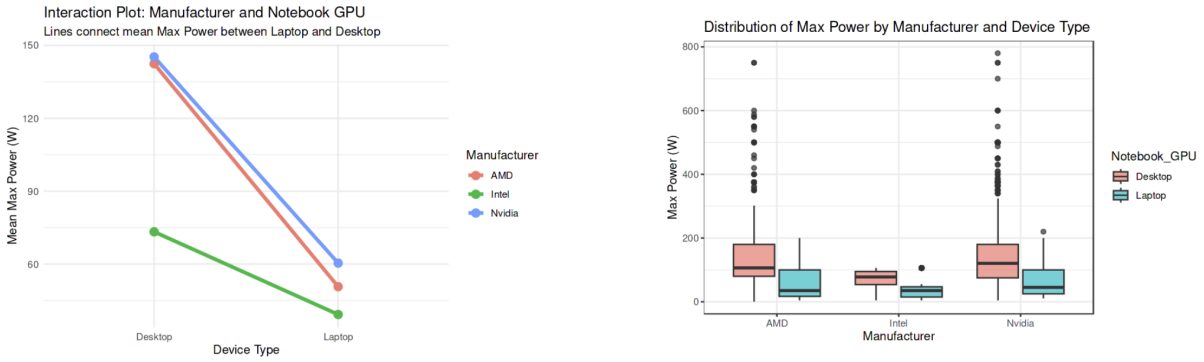

(a) (b)

Hình 25: Biểu đồ Interaction Plot (a) và biểu đồ Boxplot theo hãng và loại thiết bị (b)

Dựa vào các đường gần như song song trên biểu đồ tương tác, ta có thể thấy không có hiệu ứng tương tác đáng kể giữa hai nhân tố hãng sản xuất và loại thiết bị lên công suất tối đa.

d) Kiểm định các giả định của mô hình:

1. Tính đồng nhất của phương sai
2. Tính phân phối chuẩn của phần dư.

Tính đồng nhất của phương sai: Sử dụng kiểm định Levene's Test trên toàn bộ các tổ hợp nhóm.

```
#Khởi tạo mô hình (Xét cả hiệu ứng chính và tương tác)
model_2way <- aov(Max_Power ~ Manufacturer * Notebook_GPU, data = df_2way)
#Kiểm định Levene (Đồng nhất phương sai)
cat("--- 1. KIỂM ĐỊNH LEVENE ---\n")
print(leveneTest(Max_Power ~ Manufacturer * Notebook_GPU, data = df_2way))
```

```
--- 1. KIỂM ĐỊNH LEVENE ---
Levene's Test for Homogeneity of Variance (center = median)
        Df F value    Pr(>F)
group    5  29.456 < 2.2e-16 ***
      3194
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Hình 26: Kết quả kiểm định Levene

Nhận xét: Với mức ý nghĩa 5%, kết quả kiểm định cho thấy mô hình vi phạm giả định 1.

Tính phân phối chuẩn của phần dư: Ta sẽ sử dụng đồ thị Q-Q plot và hàm `shapiro.test()` để kiểm tra điều này.

```
cat("\n--- 2. ĐỒ THỊ Q-Q PLOT ---\n")
plot(model_2way, which = 2)
shapiro.test(residuals(model_2way))
```

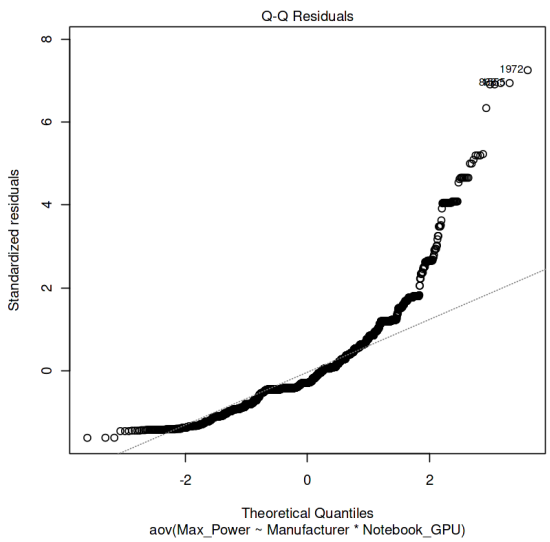

(a)

```
        Shapiro-Wilk normality test

data:  residuals(model_2way)
W = 0.8447, p-value < 2.2e-16
```

(b)

Hình 27: Biểu đồ Q-Q (a) và kết quả `shapiro.test()` (b)

Nhận xét: Ở hình trên đồ thị Q-Q plot cho thấy, phần dư không tuân theo phân phối chuẩn do các điểm lệch khỏi đường thẳng chuẩn. Tương tự với kết quả từ hàm `shapiro.test()` với mức nghĩa 5%, ta có thể kết luận phần dư của mô hình không tuân theo phân phối chuẩn.

e) Kết quả mô hình Anova 2 nhân tố:

```r
cat("\n--- 3. BẢNG KẾT QUẢ ANOVA 2 NHÂN TỐ ---\n")
print(summary(model_2way))
```

```
--- 3. BẢNG KẾT QUẢ ANOVA 2 NHÂN TỐ ---
                            Df   Sum Sq Mean Sq F value   Pr(>F)
Manufacturer                 2  1224358  612179  79.909  < 2e-16 ***
Notebook_GPU                 1  3258744 3258744 425.368  < 2e-16 ***
Manufacturer:Notebook_GPU    2   143704   71852   9.379 8.68e-05 ***
Residuals                 3194 24469217    7661
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Hình 28: Kết quả Anova hai nhân tố

Nhận xét: Với mức ý nghĩa 5%, ta kết luận có Sự tương tác. Đây là bằng chứng cho thấy một hãng cụ thể (ví dụ Nvidia) có thể có mức giảm điện năng cho Laptop vượt trội hơn so với các hãng khác.

f) Kiểm định hậu định: Do mô hình có nhiều cặp tổ hợp, kiểm định Tukey HSD được thực hiện để xác định cụ thể cặp nhóm nào có sự khác biệt về mặt thống kê

```r
cat("--- 4. KIỂM ĐỊNH HẬU ĐỊNH TUKEY HSD ---\n")
tukey_2way <- TukeyHSD(model_2way)
par(mar=c(5, 15, 4, 2))
plot(tukey_2way, las = 1, col = "darkred")
```

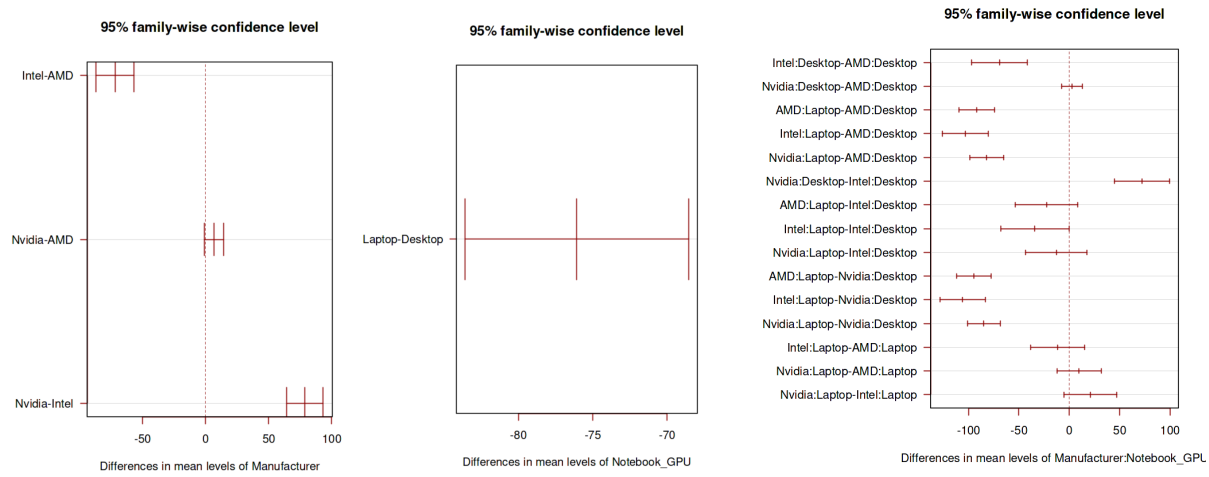

(a) (b) (c)

Hình 29: Biểu đồ kiểm định Tukey HSD so sánh khác biệt về Max Power theo từng nhân tố và hiệu ứng tương tác.

Nhận xét:

- **Hãng sản xuất (Hình a):** Cả ba hãng đều có sự khác biệt rõ rệt với nhau. Mức công suất trung bình được xếp hạng từ cao xuống thấp một cách chắc chắn là: Nvidia > AMD > Intel.
- **Loại thiết bị (Hình b):** Có sự chênh lệch cực kỳ lớn và mang ý nghĩa thống kê. Laptop có giá trị công suất trung bình thấp hơn hẳn so với Desktop (khoảng tin cậy nằm hoàn toàn ở vùng âm và cách xa mốc 0).
- **Tương tác (Hình c):** Khi xét chi tiết từng tổ hợp chéo, có rất nhiều cặp không có sự khác biệt (khoảng tin cậy cắt đường đứt nét ở mốc 0, ví dụ như mức chênh lệch giữa Nvidia Desktop và AMD Desktop là không đáng kể). Sự chênh lệch lớn nhất chủ yếu xuất hiện khi so sánh chéo giữa Desktop của các hãng mạnh với Laptop.

5.4 Bài toán hồi quy tuyến tính bội

Mục tiêu của phần này là xây dựng một mô hình hồi quy tuyến tính để mô tả và dự đoán mối quan hệ giữa các biến với`Max_Power`. Bắt đầu bằng việc chọn lọc các biến để xây dựng mô hình, sau đó từng bước đánh giá, kiểm định các giả định về mô hình.

a) Xây dựng mô hình:

```
#loại bỏ các biến phân loại
cols_to_ignore = c("Manufacturer", "Memory_Type", "Notebook_GPU")
gpu_filter <- gpu_clean[, !(names(gpu_clean) %in% cols_to_ignore)]
```

Trước tiên, ta sử dụng hàm `regsubsets()` để đánh giá tất cả các tổ hợp và chọn ra mô hình với các biến tối ưu nhất.

```
best_models <- summary(regsubsets(Max_Power ~ ., data = gpu_filter))
best_models$which
```

```
  (Intercept) Core_Speed Memory Memory_Bandwidth Memory_Speed Memory_Bus Process  ROPs  TMUs
1        TRUE      FALSE  FALSE             TRUE        FALSE      FALSE   FALSE FALSE FALSE
2        TRUE      FALSE   TRUE             TRUE        FALSE      FALSE   FALSE FALSE FALSE
3        TRUE      FALSE   TRUE             TRUE        FALSE      FALSE   FALSE  TRUE FALSE
4        TRUE      FALSE   TRUE             TRUE        FALSE      FALSE    TRUE  TRUE FALSE
5        TRUE      FALSE   TRUE             TRUE        FALSE      FALSE    TRUE  TRUE  TRUE
6        TRUE       TRUE   TRUE             TRUE        FALSE      FALSE    TRUE  TRUE  TRUE
7        TRUE       TRUE   TRUE             TRUE        FALSE       TRUE    TRUE  TRUE  TRUE
8        TRUE       TRUE   TRUE             TRUE         TRUE       TRUE    TRUE  TRUE  TRUE
```

Hình 30: Kết quả đánh giá và chọn lọc biến tối ưu cho mô hình dự đoán `Max_Power`.

```
#sử dụng $adjr2 để quan hệ số xác định của từng mô hình
best_models$adjr2
#Xác định mô hình có kết quả tốt nhất
which.max(best_models$adjr2)
```

```
> > best_models$adjr2
[1] 0.6548072 0.6740204 0.6864000 0.6935336 0.6992640 0.7025684 0.7062517 0.7071877
> which.max(best_models$adjr2)
[1] 8
```

Hình 31: Hệ số xác định của các mô hình và kết quả mô hình tốt nhất

Vậy mô hình tốt nhất cũng chính là mô hình gồm đầy đủ biến.

```
base_model <- lm(Max_Power ~ ., data = gpu_filter)
base_model
```

```
Coefficients:
     (Intercept)        Core_Speed            Memory  Memory_Bandwidth      Memory_Speed
       50.398615         -0.024896         -0.006859          0.566067         -0.010812
      Memory_Bus           Process              ROPs              TMUs
       -0.032435          0.553485          0.578076          0.330067
```

Hình 32: Hệ số của `base_model`

Ở hình 12, Ma trận tương quan cho ta thấy độ tương quan giữa `Max_Power` và các biến đều tương đối tốt, tuy nhiên độ tương quan giữa các biến với nhau cũng vậy. Vậy nên tiếp theo ta sẽ kiểm tra hiện tượng đa cộng tuyến giữa các biến.

Mức độ của hiện tượng đa cộng tuyến giữa các biến sẽ được đánh giá thông qua chỉ số VIF của từng biến độc lập, sử dụng lệnh `vif()`:

```
Core_Speed           Memory Memory_Bandwidth     Memory_Speed       Memory_Bus          Process             ROPs             TMUs
  1.609590         3.028695         8.250364         2.544467         1.668540         1.357574         4.598244         3.057897
```

Hình 33: Kết quả hàm `vif()` của `base_model`

Kết quả của lệnh trên cho thấy biến `Memory_Bandwidth` có VIF > 5, ta sẽ thử loại biến khỏi mô hình và đánh giá mô hình mới.

Ta xây dựng mô hình mới (`model_1`) với việc loại bỏ `Memory_Bandwidth` ra khỏi mô hình cũ, và tiếp tục kiểm tra bằng `vif()`.

```
model_1 <- lm(Max_Power ~ . - Memory_Bandwidth, data = gpu_filter)
vif(model_1)
```

```
Core_Speed       Memory Memory_Speed   Memory_Bus      Process         ROPs         TMUs
  1.523622     2.446143     2.029185     1.395269     1.325684     2.910248     2.880336
```

Hình 34: Kết quả hàm `vif()` của `model_1`

Các biến dự báo của mô hình lúc này đã đều có VIF < 5. Ta tiến hành so sánh 2 mô hình `model_1` và `base_model` sử dụng t-test để kiểm định hệ số hồi quy với mức ý nghĩa 5%:

$$\begin{cases} H_0 : \beta_3 = 0 \\ H_1 : \beta_3 \neq 0 \end{cases}$$

Kết quả của kiểm định này có thể được gọi ra từ lệnh `summary(base_model)`

```
summary(base_model)$coefficients["Memory_Bandwidth",]
```

```
    Estimate    Std. Error       t value      Pr(>|t|)
5.660675e-01  1.895113e-02  2.986986e+01 1.363385e-173
```

Hình 35: Kết quả kiểm định của Memory_Bandwidth

Cụ thể kết quả này được hiển thị ở cột $\Pr(> |t|)$. Có thể thấy rằng, kiểm định trên cho kết quả p-value vô cùng thấp so với mức ý nghĩa, ta có thể bác H_0.

Kiểm định trên cho ta thấy rằng mặc dù `Memory_Bandwidth` nó có độ tương quan cao với các biến khác, biến này vẫn ý nghĩa thống kê rõ rệt (p-value $\ll 0.05$). Do đó ta chấp nhận giữ lại biến này và tiếp tục tới bước kiểm định hệ số hồi quy của tất cả các biến còn lại với mức ý nghĩa 5%, sử dụng t-test:

$$\begin{cases} H_0 : \beta_i = 0 \\ H_1 : \beta_i \neq 0 \end{cases}$$

Tương tự như t-test phía trên, ta sử dụng hàm `summary()`:

```
summary(base_model)$coefficients
```

```
                    Estimate   Std. Error    t value      Pr(>|t|)
(Intercept)       50.39861477 5.4185558711   9.301116  2.467960e-20
Core_Speed        -0.02489587 0.0047368112  -5.255828  1.567926e-07
Memory            -0.00685947 0.0005812948 -11.800328  1.673789e-31
Memory_Bandwidth   0.56606749 0.0189511270  29.869859 1.363385e-173
Memory_Speed      -0.01081171 0.0031916137  -3.387537  7.135537e-04
Memory_Bus        -0.03243501 0.0044840340  -7.233444  5.835991e-13
Process            0.55348515 0.0696954521   7.941482  2.721560e-15
ROPs               0.57807615 0.0750259983   7.705011  1.721870e-14
TMUs               0.33006665 0.0309212380  10.674432  3.591745e-26
```

Hình 36: Kết quả ước lượng hệ số hồi quy và kiểm định t cho các biến của (`base_model`)

Dựa vào kết quả của lệnh trên, ta nhận thấy mọi biến hồi quy đều đã có p-value cao hơn mức ý nghĩa, ta có thể nhận mô hình này làm mô hình chính.

```
main_model <- base_model #đặt base_model thành main_model
```

$$\begin{aligned} Max_Power = \beta_0 + \beta_1 \cdot Core_Speed + \beta_2 \cdot Memory \\ + \beta_3 \cdot Memory_Bandwidth + \beta_4 \cdot Memory_Speed \\ + \beta_5 \cdot Memory_Bus + \beta_6 \cdot Process \\ + \beta_7 \cdot ROPs + \beta_8 \cdot TMUs + \epsilon \end{aligned}$$

b) Chẩn đoán mô hình với các giả định:

1. Tính tuyến tính của mô hình.
2. Sai số ngẫu nhiên là độc lập.
3. Sai số ngẫu nhiên có phân phối $N(0, \sigma^2)$
4. Sai số ngẫu nhiên có phương sai không đổi.
5. Không có sai số khi đo lường giá trị của các biến dự báo.

Trong báo cáo này, chúng ta sẽ kiểm tra lần lượt các giả định từ 1 đến 4, vì dataset được cung cấp giả định rằng các biến dự báo không có sai số đo lường, nên giả định thứ 5 mặc định thỏa.

```r
plot(main_model, which = 1)
plot(main_model, which = 2)
```

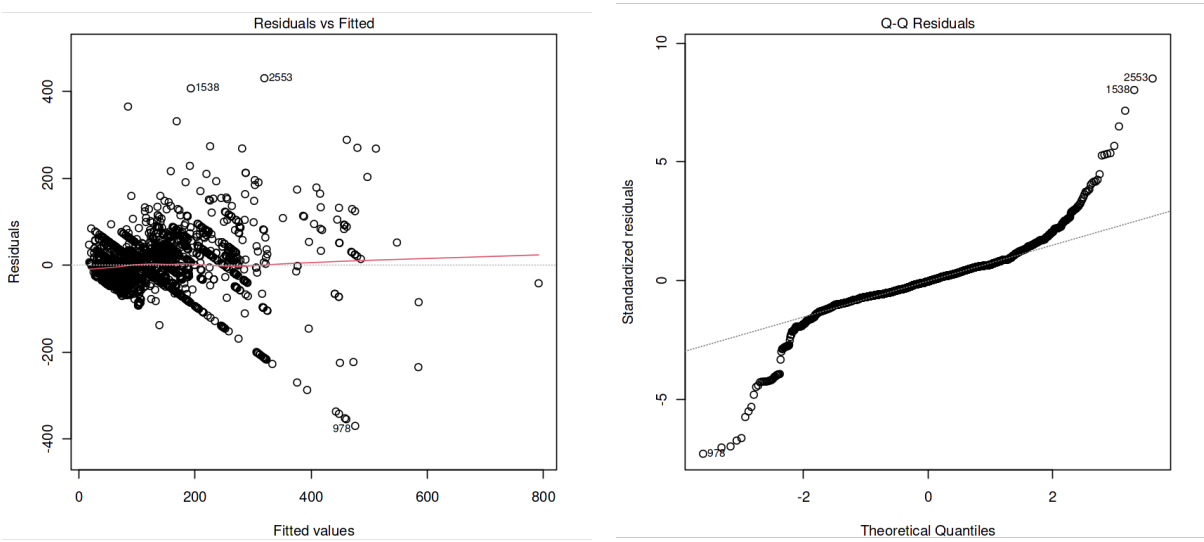

(a) (b)

Hình 37: Biểu đồ phần dư (a) và biểu đồ Q-Q của phần dư (b)

Nhận xét: Quan sát ở Hình 38, ta thấy rằng:

- Ở (a), cho thấy tính tuyến tính của mô hình có thể chấp nhận được khi đường màu đỏ có hình dạng gần với đường thẳng. Ta có thể chấp nhận được tính tuyến tính của mô hình.
- Phân bố của các giá trị phần dư có xu hương loe rộng ra và tồn tại một bộ phận có xu hướng gần như tuyến đi chéo từ vùng 0 xuống -400 từ trái sang phải. Điều này cho thấy mô hình vi phạm giả định về sai số ngẫu nhiên là độc lập và có phương sai không đổi.
- Ở (b), ta thấy có nhiều điểm lệch ra khỏi đường thẳng ở hai đầu, cho thấy phần dư không tuân theo phân phối chuẩn.

Để chắc chắn hơn, ta sẽ kiểm tra tra lại giả định 3 và 4 bằng hàm shapiro.test() và bptest():

```
        Shapiro-Wilk normality test

data:  main_model$residuals
W = 0.87479, p-value < 2.2e-16
```

(a)

```
        studentized Breusch-Pagan test

data:  main_model
BP = 767.82, df = 8, p-value < 2.2e-16
```

(b)

Hình 38: Kết quả hàm `shapiro.test()` (a) và hàm `bptest()` (b)

Với mức ý nghĩa 5%, 2 kiểm định trên cho thấy mô hình đã vi phạm giả định 3 và 4.

c) Đánh giá mô hình:

Mặc dù mô hình vi phạm một số giả định cơ bản về hồi quy tuyến tính, ta vẫn sẽ tiến hành đánh giá độ phù hợp và ý nghĩa thống kê của mô hình.

```r
summary(main_model)
```

```
Residuals:
    Min      1Q  Median      3Q     Max 
-369.96  -26.90   -1.71   25.13  430.39 

Coefficients:
                    Estimate Std. Error t value Pr(>|t|)    
(Intercept)       50.3986148  5.4185559   9.301  < 2e-16 ***
Core_Speed        -0.0248959  0.0047368  -5.256 1.57e-07 ***
Memory            -0.0068595  0.0005813 -11.800  < 2e-16 ***
Memory_Bandwidth   0.5660675  0.0189511  29.870  < 2e-16 ***
Memory_Speed      -0.0108117  0.0031916  -3.388 0.000714 ***
Memory_Bus        -0.0324350  0.0044840  -7.233 5.84e-13 ***
Process            0.5534851  0.0696955   7.941 2.72e-15 ***
ROPs               0.5780762  0.0750260   7.705 1.72e-14 ***
TMUs               0.3300667  0.0309212  10.674  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 51.05 on 3276 degrees of freedom
Multiple R-squared:  0.7079,	Adjusted R-squared:  0.7072 
F-statistic: 992.4 on 8 and 3276 DF,  p-value: < 2.2e-16
```

Hình 39: Kết quả đánh giá tổng thể mô hình `main_model`

Kiểm định hệ số hồi quy của từng biến:

$$\begin{cases} H_0 : \beta_i = 0 \\ H_1 : \beta_i \neq 0 \end{cases}$$

Kết quả: được hiện thị ở bảng Cofficients, cột $Pr(> |t|)$. p-value < 0.05 với mọi biến. Với mức ý nghĩa 5% Ta kết luận các biến đều có ý nghĩa thống kê đối với mô hình.

Sai số chuẩn của phần dư: $\sigma = 51.05$ trên 3276 bậc tự do. Ước lượng của mô hình lệch khoảng 51.05W so với thực tế. Ước lượng của mô hình lệch khoảng 51.43W so với thực tế.

Hệ số xác định: 0.7109. Các biến đầu vào giải thích được khoảng 71.09% biến thiên dữ liệu.

Kiểm định hồi quy tổng thể:

$$\begin{cases} H_0 : \beta_1 = \beta_2 = \beta_2 = \cdots = \beta_8 = 0 \\ H_1 : \text{có ít nhất một hệ số } B_i \neq 0 \end{cases}$$

Kết quả: $F = 992.4$, p-value $< 2.2 \cdot 10^{-16}$. Với mức ý nghĩa 5%, kết quả trên đã bác bỏ giả thuyết H_0, do đó mô hình có ý nghĩa thống kê.

d) Kết luận chung về mô hình:

Nhìn chung, mô hình hồi quy tuyến tính hiện tại cho thấy hiệu suất giải thích dữ liệu ở mức khá tốt ($R^2 \approx 71.09\%$) và tất cả các biến độc lập được lựa chọn đều đóng góp ý nghĩa thống kê sâu sắc vào việc dự đoán công suất tối đa (Max Power). Tuy nhiên, mức độ sai lệch dự đoán trung bình (khoảng 51.05W) là một con số cần được cân nhắc kỹ khi áp dụng vào thực tế. Đặc biệt, do mô hình vi phạm một số giả định các giá trị p-value và khoảng tin cậy được ước lượng có thể kém độ tin cậy.

6 Thảo luận và mở rộng

7 Nguồn dữ liệu và code

Tài liệu tham khảo

[1] Nguyễn Bá Thi, *Bài giảng Xác suất thống kê*

[2] Nguyễn Tiến Dũng (chủ biên), *Xác suất - thống kê và phân tích số liệu*, Nhà xuất bản Đại học Quốc gia Thành phố Hồ Chí Minh, 2020.

[3] Nguyễn Đình Huy (chủ biên), *Giáo trình xác suất và thống*, Nhà xuất bản Đại học Quốc gia Thành phố Hồ Chí Minh, 2023.

[4] D. C. Montgomery, *Applied Statistics And Probability For Engineers - 7th Edition*, Wiley Abridged Print Comp, 2017.